

ΤΕΧΝΙΚΗ ΑΝΑΦΟΡΑ

Προβλεπτική Αναλυτική Εργασία Χρονοσειρών

**Τμήμα Ψηφιακών Συστημάτων
Πανεπιστήμιο Πειραιώς**

**Ονόματα Φοιτητών:
Νούχου Μαρίνα ΑΜ: 2423
Αθανασόπουλος Παναγιώτης ΑΜ: 2402**

**Ημερομηνία:
.....3/7/2025.....**

Περίληψη

Στην παρούσα εργασία μελετώνται και αναλύονται πολλαπλές πραγματικές χρονοσειρές με στόχο τη διερεύνηση των χαρακτηριστικών τους και την αξιόπιστη πρόβλεψη μελλοντικών τιμών. Συγκεκριμένα, εξετάζονται: (α) οι ετήσιες ανωμαλίες παγκόσμιας θερμοκρασίας ξηράς (globtemp), (β) η εβδομαδιαία θνησιμότητα (cmort) στις ΗΠΑ, (γ) η μηνιαία βροχόπτωση στο Ζευγολατιό Κορινθίας (2016--2025), (δ) οι τριμηνιαίες πωλήσεις μπίρας μίας βιομηχανίας (2016--2019), καθώς και (ε) το μηνιαίο ποσοστό ανεργίας στην Ισπανία (2022--2025). Για κάθε χρονοσειρά εφαρμόζονται διαγνωστικοί έλεγχοι στασιμότητας, εποχικότητας και τάσης, ενώ προσαρμόζονται κατάλληλα μοντέλα (AR, ARIMA, SARIMA), αξιολογούνται με βάση τα κριτήρια AIC/BIC, και πραγματοποιούνται προβλέψεις με διαστήματα εμπιστοσύνης. Τα αποτελέσματα ανέδειξαν τη σημασία της σωστής προκαταρκτικής ανάλυσης για την επιλογή μοντέλου και την αξιοπιστία των προβλέψεων, ενώ καταγράφηκαν περιορισμοί των κλασικών στατιστικών μοντέλων σε δεδομένα με υψηλή μεταβλητότητα ή ακραίες τιμές.

Περιεχόμενα

1	Εισαγωγή	3
2	Βιβλιογραφική Επισκόπηση	3
3	Δεδομένα και Μεθοδολογία	3
3.1	Δεδομένα	3
3.2	Μεθοδολογία	4
4	Άσκηση 1: Ανάλυση Χρονοσειράς Ανεργίας Ισπανίας	4
4.1	Περιγραφή Δεδομένων	4
4.2	Χρονοδιάγραμμα & Εποχικότητα	6
4.3	Έλεγχος Στασιμότητας & Προσαρμογή ARMA	8
4.4	Πρώτες Διαφορές και Έλεγχος Στασιμότητας της Νέας Σειράς	10
4.5	Προσαρμογή και Αξιολόγηση Μοντέλου ARIMA(2,1,1)	10
4.6	Έλεγχος για Δεύτερες Διαφορές	12
4.7	Τελική Προσαρμογή Μοντέλου ARIMA στην Αρχική Σειρά	12
4.8	Έλεγχος Επάρκειας Μοντέλου και Σύγκριση με Διευρυμένα Μοντέλα	12
4.9	Μακροπρόθεσμη Πρόβλεψη Ποσοστού Ανεργίας και Ερμηνεία Αποτελεσμάτων	13
5	Άσκηση 2: Ανάλυση Κλιματικών Δεδομένων	15
5.1	Περιγραφή Δεδομένων	15
5.2	Χρονοδιάγραμμα, Στασιμότητα και Εποχικότητα	15
5.3	Εξέταση Στασιμότητας με ACF και PACF	16
5.4	Έλεγχος Στασιμότητας Πρώτων Εποχικών Διαφορών	17
5.5	Δυνατότητα Μοντελοποίησης με SARIMA	19
5.6	Έλεγχος Στασιμότητας Διπλών Διαφορών (Πρώτες + Εποχικές) στη Μηνιαία Βροχόπτωση	19
5.7	Προσαρμογή και Έλεγχος Μοντέλου SARIMA	21
5.8	Εφαρμογή και σύγκριση διευρυμένων μοντέλων	24
5.9	Πρόβλεψη Μηνιαίας Βροχόπτωσης για τα Επόμενα Δύο Έτη	26

6 Άσκηση 3: Ανάλυση σε cmort, globtemp και πωλήσεις μπίρας	29
6.1 Περιγραφή και Μοντελοποίηση της Χρονοσειράς Εβδομαδιαίας Θνησιμότητας cmort	29
6.1.1 Περιγραφή των Δεδομένων cmort	29
6.1.2 Προσαρμογή AR(2) Μοντέλου στη Χρονοσειρά cmort και Βραχυπρόθεσμη Πρόβλεψη	29
6.2 Ανάλυση και Πρόβλεψη Χρονοσειράς Παγκόσμιας Θερμοκρασίας Ξηράς με ARIMA	31
6.2.1 Περιγραφή της Χρονοσειράς Παγκόσμιας Θερμοκρασίας Ξηράς (globtemp)	31
6.2.2 Προκαταρκτική Ανάλυση και Στασιμότητα	32
6.2.3 Επιλογή Κατάλληλου Μοντέλου ARIMA	33
6.2.4 Διαγνωστικός Έλεγχος Μοντέλου	33
6.2.5 Πρόβλεψη για τα Επόμενα 10 Χρόνια	34
6.2.6 Συμπεράσματα	35
6.3 Ανάλυση Εποχικότητας, Τάσης και Κυκλικής Μεταβολής Πωλήσεων Μπίρας (2016--2019)	35
6.3.1 Εξάλειψη Εποχικότητας και Εποχιακοί Δείκτες	36
6.3.2 Γραμμή Τάσης (Trend Line)	36
6.3.3 Κυκλική Μεταβολή	37
6.3.4 Χρονοσειρά Πρωτογενών Πωλήσεων	37
7 Γενικά Συμπεράσματα	38
A□ Παραρτήματα	39
A□.1 Κώδικας Υλοποίησης	39

1 Εισαγωγή

Η ανάλυση χρονοσειρών αποτελεί ένα από τα βασικότερα εργαλεία στη στατιστική και την επιστήμη δεδομένων, με ευρύτατες εφαρμογές στους τομείς των οικονομικών, της μετεωρολογίας, της υγείας και της τεχνολογίας [6]. Στην παρούσα εργασία εξετάζονται πραγματικά σύνολα δεδομένων χρονοσειρών, με στόχο την κατανόηση της δυναμικής τους, την ανίχνευση τάσεων και εποχικότητας, καθώς και την πρόβλεψη μελλοντικών τιμών μέσω κατάλληλων στοχαστικών μοντέλων όπως τα ARIMA και SARIMA. Παρουσιάζονται τεχνικές προκαταρκτικής ανάλυσης, έλεγχοι στασιμότητας και διαγνωστικοί έλεγχοι των επιλεγμένων μοντέλων, ενώ δίνεται ιδιαίτερη έμφαση στην αξιολόγηση της προγνωστικής τους ικανότητας.

Η δομή της εργασίας περιλαμβάνει αρχικά μια σύντομη θεωρητική επισκόπηση των βασικών εννοιών, ακολουθεί αναλυτική περιγραφή των δεδομένων και της μεθοδολογίας, και στη συνέχεια εφαρμόζεται η κατάλληλη στατιστική ανάλυση σε κάθε χρονοσειρά ξεχωριστά, με αναλυτική παρουσίαση των αποτελεσμάτων και των συμπερασμάτων.

2 Βιβλιογραφική Επισκόπηση

Η ανάλυση χρονοσειρών αποτελεί βασικό εργαλείο για την κατανόηση και πρόβλεψη φαινομένων που εξελίσσονται στο χρόνο [11]. Μια χρονοσειρά είναι μια ακολουθία μετρήσεων που καταγράφονται σε διαδοχικές χρονικές στιγμές και εμφανίζουν συχνά εξαρτήσεις μεταξύ των διαδοχικών τιμών [6].

Στασιμότητα: Σημαντική προϋπόθεση για την ανάλυση χρονοσειρών είναι η στασιμότητα, δηλαδή η διατήρηση σταθερών στατιστικών χαρακτηριστικών (μέση τιμή, διακύμανση) στο χρόνο [11]. Η έλλειψη στασιμότητας (π.χ. λόγω τάσης ή εποχικότητας) συχνά αντιμετωπίζεται με κατάλληλους μετασχηματισμούς, όπως διαφοροποίηση.

Εποχικότητα: Πολλές χρονοσειρές παρουσιάζουν εποχικότητα, δηλαδή περιοδικά μοτίβα που επαναλαμβάνονται κάθε συγκεκριμένο διάστημα (π.χ. ετήσιο, μηνιαίο) [3]. Η ανάλυση εποχικότητας βοηθάει στην κατανόηση και αφαίρεση αυτών των περιοδικών επιδράσεων για καλύτερη πρόβλεψη.

Μοντέλα ARIMA/SARIMA: Τα μοντέλα ARIMA (AutoRegressive Integrated Moving Average) είναι ευρέως διαδεδομένα για την πρόβλεψη χρονοσειρών, καθώς μπορούν να χειριστούν τόσο στατικές όσο και μη-στατικές σειρές [1]. Τα μοντέλα SARIMA (Seasonal ARIMA) επεκτείνουν τα ARIMA ώστε να λαμβάνουν υπόψη και την εποχικότητα της σειράς, ενσωματώνοντας εποχικούς όρους στο μοντέλο [10].

Η επιλογή και η ορθή εφαρμογή αυτών των μοντέλων απαιτεί τη διενέργεια κατάλληλων διαγνωστικών ελέγχων και τη χρήση στατιστικών κριτηρίων, όπως το AIC και το BIC, για τη βέλτιστη προσαρμογή στα δεδομένα [6].

3 Δεδομένα και Μεθοδολογία

3.1 Δεδομένα

Στην παρούσα εργασία μελετώνται και αναλύονται πολλαπλές πραγματικές χρονοσειρές με στόχο τη διερεύνηση των χαρακτηριστικών τους και την αξιόπιστη πρόβλεψη

μελλοντικών τιμών. Συγκεκριμένα, εξετάζονται:

- **Ετήσιες ανωμαλίες παγκόσμιας θερμοκρασίας ξηράς (globtemp):** Ετήσια δεδομένα από το 1850 έως το 2023 που καταγράφουν τη μεταβολή της μέσης θερμοκρασίας της ξηράς σε παγκόσμιο επίπεδο.
- **Εβδομαδιαία θνησιμότητα (cmort) στις ΗΠΑ:** Εβδομαδιαία στοιχεία θανάτων, που συχνά χρησιμοποιούνται για ανάλυση επιδημιολογικών φαινομένων και πρόβλεψη.
- **Μηνιαία βροχόπτωση στο Ζευγολατιό Κορινθίας:** Μηνιαίες τιμές βροχόπτωσης για τα έτη 2016--2025, όπως συλλέχθηκαν από μετεωρολογικούς σταθμούς της περιοχής.
- **Τριμηνιαίες πωλήσεις μπίρας μίας βιομηχανίας:** Δεδομένα πωλήσεων (σε εκατομμύρια φιάλες) ανά εποχή (Χειμώνας, Άνοιξη, Καλοκαίρι, Φθινόπωρο) για τα έτη 2016--2019.
- **Μηνιαίο ποσοστό ανεργίας στην Ισπανία:** Μηνιαία δεδομένα ανεργίας από την Eurostat και το INE για την περίοδο Ιανουαρίου 2022 έως Απριλίου 2025.

3.2 Μεθοδολογία

Η ανάλυση των χρονοσειρών περιλαμβάνει τα εξής βήματα:

- **Προκαταρκτική ανάλυση:** Οπτικοποίηση και στατιστικός έλεγχος για στάσιμη ή μη στάσιμη συμπεριφορά (με χρήση διαγραμμάτων, ACF/PACF και τεστ στασιμότητας).
- **Αποσύνθεση και προεπεξεργασία:** Αφαίρεση τάσης και εποχικότητας, όπου απαιτείται, με χρήση διαφορικών ή αποσύνθεσης (multiplicative/additive decomposition).
- **Εφαρμογή κατάλληλων μοντέλων:** Προσαρμογή μοντέλων AR, MA, ARMA, ARIMA ή SARIMA ανάλογα με τα χαρακτηριστικά της κάθε σειράς.
- **Διαγνωστικός έλεγχος:** Έλεγχος λευκού θορύβου στα υπόλοιπα (τεστ Ljung-Box), αξιολόγηση κατανομής σφαλμάτων (QQ-plot, ιστογράμματα) και μετρικές αξιολόγησης (MSE, RMSE, MAE, AIC, BIC).
- **Πρόβλεψη:** Εκτίμηση μελλοντικών τιμών με διαστήματα εμπιστοσύνης και οπτικοποίηση των αποτελεσμάτων.
- **Σύγκριση και εξαγωγή συμπερασμάτων:** Σύνοψη αποτελεσμάτων, σύγκριση μοντέλων και ερμηνεία για κάθε χρονοσειρά.

4 Άσκηση 1: Ανάλυση Χρονοσειράς Ανεργίας Ισπανίας

4.1 Περιγραφή Δεδομένων

Για την ανάλυση της χρονοσειράς ποσοστού ανεργίας, χρησιμοποιήθηκαν μηνιαία δεδομένα ανεργίας της Ισπανίας για την περίοδο Ιανουάριος 2022 έως Απρίλιος 2025.

Τα δεδομένα συλλέχθηκαν από επίσημες στατιστικές πηγές όπως η Eurostat [5] και το INE - Instituto Nacional de Estadística [4], καλύπτοντας συνολικά 40 διαδοχικές μηνιαίες παρατηρήσεις. Κάθε παρατήρηση αντιστοιχεί στο ποσοστό ανεργίας (%) του εργατικού δυναμικού της Ισπανίας για τον αντίστοιχο μήνα.

Το χρονικό αυτό διάστημα επιλέχθηκε ώστε να περιλαμβάνει τόσο ενδεχόμενες βραχυχρόνιες διακυμάνσεις όσο και μακροπρόθεσμες τάσεις, καθώς και την επίδραση εποχικών παραγόντων (π.χ. τουριστική περίοδος, χειμερινή ύφεση). Η μορφή των δεδομένων είναι μονοδιάστατη αριθμητική ακολουθία (time series), όπου κάθε στοιχείο αντιστοιχεί σε έναν μήνα και έχει τη δομή: [Έτος, Μήνας, Ποσοστό Ανεργίας (%)].

Στον Πίνακα 1 παρουσιάζονται ενδεικτικά οι πρώτες και οι τελευταίες τιμές της χρονοσειράς, ενώ στο παρακάτω διάγραμμα (Εικόνα 1) απεικονίζεται η χρονική εξέλιξη του ποσοστού ανεργίας για το εξεταζόμενο διάστημα.



Σχήμα 1: Μηνιαία εξέλιξη του ποσοστού ανεργίας στην Ισπανία (Ιαν. 2022 -- Απρ. 2025)

Ενδεικτική μορφή δεδομένων:


Πίνακας 1: Ενδεικτικές Τιμές Μηνιαίου Ποσοστού Ανεργίας στην Ισπανία (2022--2025)

Έτος	Μήνας	Ποσοστό Ανεργίας (%)
2022	01	13.6
2022	02	13.8
2022	03	13.8
2022	04	13.1
2022	05	12.5
2022	06	12.4
⋮	⋮	⋮
2025	01	11.2
2025	02	11.5
2025	03	11.5
2025	04	10.9

Η συγκεκριμένη χρονοσειρά παρουσιάζει χαρακτηριστικά έντονων διακυμάνσεων, με ετήσια εποχικότητα και εμφανή καθοδική τάση, όπως αναλύεται στις επόμενες ενότητες.


4.2 Χρονοδιάγραμμα & Εποχικότητα

Η εξέλιξη του ποσοστού ανεργίας στην Ισπανία για την περίοδο Ιανουαρίου 2022 έως Απριλίου 2025 παρουσιάζει έντονη καθοδική τάση, με τη μέση ανεργία να μειώνεται από περίπου 13,8% στις αρχές του 2022 σε 10,9% τον Απρίλιο του 2025, όπως φαίνεται στο Σχήμα 2.




Σχήμα 2: Μηνιαία εξέλιξη του ποσοστού ανεργίας στην Ισπανία (Ιαν. 2022 -- Απρ. 2025)

Η χρονοσειρά αυτή χαρακτηρίζεται ως μη στάσιμη, καθώς τόσο ο μέσος όσο και η διακύμανση μεταβάλλονται σημαντικά με την πάροδο του χρόνου, ενώ παρατηρείται παράλληλα και ισχυρή εποχικότητα. Η ανάλυση εποχικότητας και τα αντίστοιχα γραφήματα (Σχήμα 3) αποκαλύπτουν ένα ετήσιο επαναλαμβανόμενο μοτίβο, με σαφείς κορυφώσεις της ανεργίας τους μήνες Ιανουάριο έως Μάρτιο και χαμηλότερα επίπεδα την περίοδο Μαΐου--Ιουνίου.




Σχήμα 3: Αποσύνθεση χρονοσειράς: Τάση, εποχικότητα και τυχαίο στοιχείο

Αυτή η εποχικότητα επιβεβαιώνεται τόσο από τα στατιστικά boxplots ανά μήνα (Σχήμα 4), όπου διακρίνονται σημαντικές διαφορές μεταξύ μηνιαίων τιμών, όσο και από τη συνάρτηση αυτοσυσχέτισης (ACF, Σχήμα 5), η οποία εμφανίζει μέγιστα ανά 12 μήνες.



Σχήμα 4: Boxplot εποχικής διακύμανσης ποσοστού ανεργίας ανά μήνα



Σχήμα 5: Συνάρτηση αυτοσυσχέτισης (ACF) της χρονοσειράς ανεργίας

Οι παρατηρούμενες διακυμάνσεις συνδέονται κυρίως με τον εποχικό χαρακτήρα της ισπανικής οικονομίας, καθώς η τουριστική περίοδος οδηγεί σε αύξηση της απασχόλησης τους θερινούς μήνες, ενώ οι γιορτινές περιόδους και ο χειμώνας συνδέονται με προσωρινές απολύσεις και αύξηση της ανεργίας.


Συμπερασματικά, η ανάλυση της χρονοσειράς της ανεργίας στην Ισπανία αναδεικνύει τόσο τη σημαντική καθοδική τάση, όσο και την έντονη ετήσια εποχικότητα, γεγονός που υποδεικνύει την ανάγκη για προσαρμοσμένες πολιτικές απασχόλησης που να λαμβάνουν υπόψη τους αυτούς τους δομικούς και κυκλικούς παράγοντες.

4.3 Έλεγχος Στασιμότητας & Προσαρμογή ARMA


Για τη διερεύνηση της στασιμότητας της χρονοσειράς του ποσοστού ανεργίας στην Ισπανία, εξετάστηκαν τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF). Τα αρχικά διαγράμματα ACF και PACF της σειράς έδειξαν σημαντικές τιμές σε πολλούς διαδοχικούς χρόνους υστέρησης (lags), γεγονός που υποδηλώνει ότι η χρονοσειρά δεν είναι στάσιμη. Για τον λόγο αυτό εφαρμόστηκαν πρώτες διαφορές, ώστε να καταστεί η σειρά στάσιμη. Η γραφική παράσταση των πρώτων διαφορών (Εικόνα 8) δείχνει ότι τα δεδομένα διασπείρονται συμμετρικά γύρω από το μηδέν, χαρακτηριστικό στάσιμης σειράς.

Η στασιμότητα της νέας σειράς επιβεβαιώνεται από το ACF των πρώτων διαφορών (Εικόνα 6), όπου οι τιμές μηδενίζονται γρήγορα μετά το lag 1, και από το PACF (Εικόνα 7), όπου παρατηρείται μια σημαντική τιμή στο πρώτο lag. Η μορφή αυτή των συντελεστών υποδεικνύει ότι η σειρά των πρώτων διαφορών μπορεί να μοντελοποιηθεί κατάλληλα με ένα μοντέλο ARMA. Δοκιμάστηκαν τα μοντέλα ARMA(2,1) και ARMA(1,1), με κριτήριο επιλογής το Akaike Information Criterion (AIC) και την ανάλυση των καταλοίπων. Το μοντέλο ARMA(2,1) εμφάνισε χαμηλότερο AIC, όλους τους συντελεστές στατιστικά σημαντικούς και τα κατάλοιπά του παρουσίαζαν χαρακτηριστικά λευκού θορύβου, επιβεβαιώνοντας την καλή προσαρμογή (Εικόνα 9).


Η πρόβλεψη των πρώτων διαφορών με το επιλεγμένο μοντέλο για τους επόμενους μήνες απεικονίζεται στο διάγραμμα 24, όπου οι προβλεπόμενες τιμές παραμένουν κοντά στο μηδέν, συμβαδίζοντας με το χαρακτηριστικό της στασιμότητας. Συνολικά, η διαδικασία στασιμότητας και η προσαρμογή του μοντέλου ARMA(2,1) εξασφαλίζει αξιόπιστη βραχυπρόθεσμη πρόβλεψη της χρονοσειράς της ανεργίας.




Σχήμα 6: ACF πρώτων διαφορών της χρονοσειράς ανεργίας




Σχήμα 7: PACF πρώτων διαφορών της χρονοσειράς ανεργίας



Σχήμα 8: Γραφική απεικόνιση πρώτων διαφορών ποσοστού ανεργίας (σταθ/η σειρά)



Σχήμα 9: ACF και PACF residuals του προσαρμοσμένου μοντέλου ARMA



Σχήμα 10: Πρόβλεψη πρώτων διαφορών ποσοστού ανεργίας με το μοντέλο ARMA(2,1)

4.4 Πρώτες Διαφορές και Έλεγχος Στασιμότητας της Νέας Σειράς

Σε συνέχεια της διαπίστωσης ότι η αρχική χρονοσειρά ποσοστού ανεργίας δεν είναι στάσιμη, υπολογίστηκε η σειρά των πρώτων διαφορών, δηλαδή η διαφορά κάθε τιμής από την προηγούμενη. Η γραφική απεικόνιση αυτής της σειράς φαίνεται στο Σχήμα 8. Για τη νέα χρονοσειρά εφαρμόστηκαν εκ νέου οι συντελεστές αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) (Σχήματα 6, 7). Τα αποτελέσματα δείχνουν ότι τόσο το ACF όσο και το PACF μηδενίζονται γρήγορα, ένδειξη ότι η σειρά των πρώτων διαφορών είναι πλέον στάσιμη. Έτσι, καθίσταται κατάλληλη για μοντελοποίηση με ARMA ή ARIMA.

4.5 Προσαρμογή και Αξιολόγηση Μοντέλου ARIMA(2,1,1)

Για την πρόβλεψη του ποσοστού ανεργίας στην Ισπανία εφαρμόστηκε μοντέλο ARIMA(2,1,1) στα μηνιαία δεδομένα της περιόδου ανάλυσης. Οι εκτιμημένες παράμετροι του μοντέλου συνοψίζονται στον Πίνακα 2.


Πίνακας 2: Εκτιμήσεις παραμέτρων του μοντέλου ARIMA(2,1,1)

Παράμετρος	Εκτίμηση	Τυπικό Σφάλμα	z-value	p-value
ar1	1.02	0.18	5.64	< 0.001
ar2	-0.68	0.13	-5.29	< 0.001
ma1	-0.32	0.22	-1.46	0.143

Σχολιασμός: Οι συντελεστές ar1 και ar2 είναι στατιστικά σημαντικοί ($p\text{-value} < 0.05$), ενώ ο συντελεστής ma1 δεν είναι στατιστικά σημαντικός, αλλά παραμένει στο μοντέλο για τη βελτίωση της προσαρμογής.

Έλεγχος Καταλοίπων: Ο διαγνωστικός έλεγχος των καταλοίπων μέσω των διαγραμμάτων αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) δεν ανέδειξε ισχυρές αυτοσυσχετίσεις, ενώ το τεστ Box-Ljung ($p\text{-value} = 0.024$) υποδεικνύει οριακή στατιστική σημαντικότητα. Αυτό σημαίνει ότι ενδέχεται να υπάρχουν μικρές υπολειμματικές συσχετίσεις που δεν έχουν απορροφηθεί πλήρως από το μοντέλο.

Πρόβλεψη και Διάγραμμα: Στο Σχήμα 11 παρουσιάζονται η ιστορική χρονοσειρά του ποσοστού ανεργίας (μαύρη γραμμή), οι προβλέψεις του μοντέλου για τους επόμενους 12 μήνες (κόκκινη γραμμή) και τα 95% διαστήματα εμπιστοσύνης (μπλε διακεκομμένη γραμμή).



Σχήμα 11: Πρόβλεψη ανεργίας στην Ισπανία με το μοντέλο ARIMA(2,1,1).

Σχολιασμός: Η πρόβλεψη δείχνει σχετική σταθεροποίηση του ποσοστού ανεργίας κατά το επόμενο έτος, χωρίς ακραίες διακυμάνσεις. Τα διαστήματα εμπιστοσύνης διευρύνονται όσο μεγαλώνει ο χρονικός ορίζοντας, κάτι αναμενόμενο λόγω της αυξανόμενης αβεβαιότητας στη μακροπρόθεσμη πρόβλεψη.

Συμπέρασμα: Το μοντέλο ARIMA(2,1,1) παρέχει ικανοποιητική προσαρμογή στα δεδομένα και αξιόπιστες βραχυπρόθεσμες προβλέψεις για την ανεργία στην Ισπανία. Εντοπίζονται μικρές ενδείξεις υπολειμματικής αυτοσυσχέτισης, οι οποίες θα μπορούσαν να αντιμετωπιστούν με δοκιμή πιο σύνθετων μοντέλων ή ενσωμάτωση επιπλέον εξωγενών μεταβλητών, εφόσον αυτές είναι διαθέσιμες.

4.6 Έλεγχος για Δεύτερες Διαφορές

Σύμφωνα με τα αποτελέσματα των ενοτήτων 4.4 και 4.5, διαπιστώθηκε ότι η σειρά των πρώτων διαφορών της αρχικής χρονοσειράς είναι ήδη στάσιμη, όπως προκύπτει από την ανάλυση των διαγραμμάτων αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF). Επομένως, δεν απαιτείται ο υπολογισμός δεύτερων διαφορών, ούτε περαιτέρω έλεγχος στασιμότητας για τη νέα σειρά. Η στάσιμη σειρά των πρώτων διαφορών κρίνεται κατάλληλη για τη μοντελοποίηση με ARMA ή ARIMA, όπως εφαρμόστηκε στις προηγούμενες ενότητες.

4.7 Τελική Προσαρμογή Μοντέλου ARIMA στην Αρχική Σειρά

Όπως διαπιστώθηκε από την ανάλυση των πρώτων διαφορών της χρονοσειράς ποσοστού ανεργίας, η νέα σειρά εμφανίζει σαφή στασιμότητα και επομένως καθίσταται κατάλληλη για μοντελοποίηση με ARMA ή ARIMA μοντέλα με $d=1$. Στο πλαίσιο αυτό, προσαρμόστηκε το μοντέλο **ARIMA(2,1,1)** στα αρχικά δεδομένα, λαμβάνοντας υπόψη μία διαφορά ($d=1$). Τα αποτελέσματα του μοντέλου δείχνουν ικανοποιητική προσαρμογή και επαρκή απόσβεση της αυτοσυσχέτισης στα κατάλοιπα, ενώ οι προβλέψεις που προκύπτουν χαρακτηρίζονται από ρεαλιστική συμπεριφορά και αναμενόμενη αβεβαιότητα στο διάστημα πρόβλεψης. Συνεπώς, το μοντέλο ARIMA(2,1,1) αποτελεί την καταλληλότερη επιλογή για τη χρονοσειρά της ανεργίας στην Ισπανία για την εξεταζόμενη περίοδο.

4.8 Έλεγχος Επάρκειας Μοντέλου και Σύγκριση με Διευρυμένα Μοντέλα

Για την αξιολόγηση της επάρκειας του τελικού μοντέλου **ARIMA(2,1,1)**, πραγματοποιήθηκε ανάλυση των υπολοίπων καθώς και σύγκριση με μοντέλα ευρύτερης τάξης.

(I) **Έλεγχος Υπολοίπων:** Τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) των υπολοίπων του μοντέλου (Figure 12) δείχνουν ότι οι τιμές κινούνται εντός των ορίων σημαντικότητας, χωρίς ενδείξεις έντονης αυτοσυσχέτισης. Ωστόσο, το τεστ Box-Ljung για τα κατάλοιπα επιστρέφει p-value λίγο μικρότερο του 0.05 ($p=0.024$), υποδεικνύοντας την πιθανή ύπαρξη ελαφριάς υπολειμματικής δομής που δεν έχει απορροφηθεί πλήρως από το μοντέλο.


(II) **Σύγκριση με Διευρυμένα Μοντέλα:** Δοκιμάστηκαν επιπλέον ARIMA μοντέλα ευρύτερης τάξης (ARIMA(3,1,1), ARIMA(2,1,2), ARIMA(2,2,1)) και συγκρίθηκαν βάσει του κριτηρίου AIC και του p-value του τεστ Box-Ljung για τα κατάλοιπα. Τα αποτελέσματα συνοψίζονται στον Πίνακα 3.

Πίνακας 3: Σύγκριση μοντέλων ARIMA ως προς το AIC και το p-value του Box-Ljung.

Μοντέλο	AIC	Box-Ljung p-value
ARIMA(2,1,1)	13.48	0.024
ARIMA(3,1,1)	12.05	0.071
ARIMA(2,1,2)	5.88	0.0003
ARIMA(2,2,1)	17.79	0.0073

Το μοντέλο **ARIMA(2,1,2)** εμφανίζει τον χαμηλότερο δείκτη AIC, ωστόσο το p-value του τεστ Box-Ljung είναι ιδιαίτερα μικρό (0.0003), κάτι που δείχνει σημαντική αυτοσυσχέτιση στα κατάλοιπα και συνεπώς ακαταλληλότητα. Αντίθετα, το μοντέλο **ARIMA(3,1,1)** έχει σχετικά χαμηλό AIC και αποδεκτό p-value (0.071), γεγονός που υποδεικνύει καλύτερη στατιστική επάρκεια σε σχέση με το ARIMA(2,1,1).

Συμπέρασμα: Παρότι το αρχικό μοντέλο ARIMA(2,1,1) απορροφά τη βασική δυναμική της χρονοσειράς, το διευρυμένο μοντέλο ARIMA(3,1,1) προσφέρει ελαφρώς καλύτερη συμπεριφορά ως προς την επάρκεια των υπολοίπων. Η επιλογή του τελικού μοντέλου θα πρέπει να βασιστεί σε συνδυασμό δεικτών επάρκειας (AIC, Box-Ljung test) και ερμηνευσιμότητας, με προτίμηση προς το ARIMA(3,1,1) αν η στατιστική επάρκεια αποτελεί προτεραιότητα. Η ύπαρξη χαμηλού AIC αποτελεί ένδειξη καλής προσαρμογής, ωστόσο η έλλειψη αυτοσυσχέτισης στα κατάλοιπα διασφαλίζει την εγκυρότητα των προβλέψεων του μοντέλου. Γι' αυτό, όταν υπάρχει σύγκρουση ανάμεσα σε AIC και στατιστική επάρκεια, προτιμάται το μοντέλο με καλύτερη συμπεριφορά καταλοίπων. Στη στατιστική μοντελοποίηση χρονοσειρών, η επιλογή τελικού μοντέλου βασίζεται όχι μόνο σε δείκτες προσαρμογής (όπως το AIC) αλλά και στην απουσία δομής στα κατάλοιπα, ώστε οι υποθέσεις του μοντέλου να τηρούνται.



Σχήμα 12: ACF και PACF υπολοίπων για το μοντέλο ARIMA(2,1,2).


4.9 Μακροπρόθεσμη Πρόβλεψη Ποσοστού Ανεργίας και Ερμηνεία Αποτελεσμάτων

Για την πρόβλεψη της μελλοντικής πορείας του ποσοστού ανεργίας στην Ισπανία εφαρμόστηκε το τελικό μοντέλο **ARIMA(3,1,1)**, το οποίο επιλέχθηκε ως καταλληλότερο μεταξύ διαφόρων υποψήφιων μοντέλων βάσει των στατιστικών κριτηρίων (χαμηλότερο AIC, ικανοποιητική επάρκεια υπολοίπων).

Στο Figure 13 παρουσιάζεται η πρόβλεψη του ποσοστού ανεργίας για τους επόμενους 24 μήνες:

- Η μαύρη γραμμή αντιστοιχεί στα ιστορικά παρατηρημένα δεδομένα.

- **Η κόκκινη γραμμή** παρουσιάζει τις προβλεπόμενες τιμές για το ποσοστό ανεργίας με βάση το επιλεγμένο μοντέλο $ARIMA(3,1,1)$.
- **Οι μπλε διακεκομμένες γραμμές** οριοθετούν το 95% διάστημα εμπιστοσύνης των προβλέψεων.



Σχήμα 13: Πρόβλεψη ποσοστού ανεργίας για τα επόμενα 24 μήνες με το μοντέλο $ARIMA(3,1,1)$.

Σχολιασμός Αποτελεσμάτων:

- **Σχετική σταθεροποίηση:** Η πρόβλεψη του ποσοστού ανεργίας παραμένει σε παρόμοια επίπεδα με τα τελευταία παρατηρούμενα δεδομένα, χωρίς να εμφανίζεται έντονη ανοδική ή καθοδική τάση.
- **Ελαφριά διακύμανση:** Διακρίνονται μικρές κυκλικές διακυμάνσεις στις προβλεπόμενες τιμές, οι οποίες πιθανώς οφείλονται στην εποχικότητα που έχει ενσωματωθεί στο μοντέλο από το ιστορικό δείγμα.
- **Αβεβαιότητα:** Τα διαστήματα εμπιστοσύνης (95%) διευρύνονται όσο αυξάνεται ο χρονικός ορίζοντας της πρόβλεψης, κάτι που αντανάκλα τη φυσιολογική αύξηση της αβεβαιότητας στη μακροπρόθεσμη εκτίμηση.
- **Απουσία ακραίων τιμών:** Δεν παρατηρούνται ακραίες προβλεπόμενες τιμές ή τάσεις εκθετικής αύξησης/μείωσης, γεγονός που υποδηλώνει ότι το μοντέλο έχει συγκρατημένη και ρεαλιστική συμπεριφορά στις προβλέψεις του.

Συμπέρασμα: Το τελικό μοντέλο $ARIMA(3,1,1)$ προσφέρει αξιόπιστες βραχυπρόθεσμες και μεσοπρόθεσμες προβλέψεις για το ποσοστό ανεργίας, εμφανίζοντας σχετική σταθερότητα και ικανοποιητική ερμηνευσιμότητα. Η προβλεπτική ακρίβεια μειώνεται, όπως αναμενόταν, όσο αυξάνει ο χρονικός ορίζοντας της πρόβλεψης, όπως αποτυπώνεται από τη διεύρυνση των διαστημάτων εμπιστοσύνης.

5 Άσκηση 2: Ανάλυση Κλιματικών Δεδομένων

5.1 Περιγραφή Δεδομένων

Για την ανάλυση της μηνιαίας βροχόπτωσης στο Ζευγολατιό Κορινθίας κατά την περίοδο 2016–2025, χρησιμοποιήθηκαν ανοικτά μετεωρολογικά δεδομένα που αντλήθηκαν από την πλατφόρμα open-meteo.com [9]. Τα αρχικά δεδομένα αφορούσαν ημερήσιες τιμές βροχόπτωσης (σε χιλιοστά, mm) για κάθε ημερολογιακή ημέρα της περιόδου μελέτης.

Αρχικά, τα δεδομένα εισήχθησαν στο περιβάλλον R και πραγματοποιήθηκε καθαρισμός ώστε να αφαιρεθούν οι γραμμές μεταδεδομένων από το αρχείο κατά την ανάγνωση. Η στήλη της ημερομηνίας (time) μετατράπηκε σε τύπο Date και στη συνέχεια εξήχθησαν το έτος και ο μήνας από κάθε εγγραφή. Για τη δημιουργία της μηνιαίας χρονοσειράς, ομαδοποιήθηκαν οι ημερήσιες τιμές κατά έτος και μήνα, και υπολογίστηκε το συνολικό ύψος βροχόπτωσης ανά μήνα με χρήση της συνάρτησης aggregate στη γλώσσα R.

Το τελικό αποτέλεσμα είναι μια μονοδιάστατη χρονοσειρά που αποτυπώνει το μηνιαίο ύψος βροχής (σε mm) για κάθε μήνα από τον Ιανουάριο 2016 έως τον Ιούνιο 2025. Η παρακάτω γραφική παράσταση (Figure 14) απεικονίζει τη χρονική εξέλιξη της βροχόπτωσης για το διάστημα μελέτης.

Τα συγκεκριμένα δεδομένα αποτελούν τη βάση για την ανάλυση της χρονοσειράς και την πρόβλεψη της βροχόπτωσης στην περιοχή.

5.2 Χρονοδιάγραμμα, Στασιμότητα και Εποχικότητα

Στο Σχήμα 14 παρουσιάζεται το χρονοδιάγραμμα της μηνιαίας βροχόπτωσης για το Ζευγολατιό Κορινθίας κατά την περίοδο 2016–2025.

Από το διάγραμμα παρατηρούμε ότι:

- Υπάρχουν μεγάλες διακυμάνσεις στην ποσότητα βροχής από χρόνο σε χρόνο, καθώς και κάποιες περίοδοι με ιδιαίτερα έντονες βροχοπτώσεις. Αυτό υποδεικνύει ότι ο μέσος όρος και η διακύμανση της σειράς μεταβάλλονται στον χρόνο, συνεπώς η χρονοσειρά δεν μπορεί να χαρακτηριστεί ως στάσιμη.
- Επιπλέον, διακρίνονται επαναλαμβανόμενα μοτίβα μέσα στο έτος, με αυξημένη βροχόπτωση τους χειμερινούς μήνες και μειωμένη το καλοκαίρι. Το γεγονός αυτό αποτελεί σαφή ένδειξη ύπαρξης ετήσιας εποχικότητας στη σειρά.


Συμπερασματικά, η μηνιαία βροχόπτωση παρουσιάζει ισχυρή εποχικότητα και μη στασιμότητα, καθώς οι στατιστικές ιδιότητες της σειράς (μέσος, διακύμανση) μεταβάλλονται με την πάροδο του χρόνου και επηρεάζονται από τις εποχικές κλιματικές συνθήκες της περιοχής.




Σχήμα 14: Μηνιαία βροχόπτωση (σε mm) στο Ζευγολατιό Κορινθίας για την περίοδο 2016–2025, όπως υπολογίστηκε από τα ημερήσια δεδομένα της πλατφόρμας open-meteo.com.

5.3 Εξέταση Στασιμότητας με ACF και PACF

Για τη διερεύνηση της στασιμότητας της μηνιαίας χρονοσειράς βροχόπτωσης Ζευγολατιού Κορινθίας, εξετάστηκαν τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF), τα οποία παρουσιάζονται στα Σχήματα 15 και 16.



Σχήμα 15: Διάγραμμα αυτοσυσχέτισης (ACF) μηνιαίας βροχόπτωσης Ζευγολατιού Κορινθίας.



Σχήμα 16: Διάγραμμα μερικής αυτοσυσχέτισης (PACF) μηνιαίας βροχόπτωσης Ζευγολατιού Κορινθίας.

Σχολιασμός: Παρατηρούμε ότι το ACF παρουσιάζει πολύ υψηλή τιμή στο πρώτο lag και στη συνέχεια οι τιμές μειώνονται σχετικά αργά, με τα περισσότερα επόμενα lags να βρίσκονται εντός των διαστημάτων εμπιστοσύνης. Αντίστοιχα, το PACF εμφανίζει σημαντική τιμή μόνο στο πρώτο lag, ενώ τα υπόλοιπα lags είναι χαμηλά.

Το συγκεκριμένο μοτίβο, σε συνδυασμό με το χρονοδιάγραμμα της σειράς, υποδηλώνει ότι η χρονοσειρά δεν είναι στάσιμη. Η ύπαρξη σημαντικής αυτοσυσχέτισης στο lag 1 και η καθυστερημένη εξασθένιση των τιμών αποτελούν ενδείξεις μη στασιμότητας, ενώ παράλληλα το χρονοδιάγραμμα (βλ. προηγούμενη ενότητα) έδειξε έντονη εποχικότητα και διακυμάνσεις στο μέσο όρο.

Συμπέρασμα: Η χρονοσειρά μηνιαίας βροχόπτωσης του Ζευγολατιού Κορινθίας δεν είναι στάσιμη. Για να επιτευχθεί στασιμότητα, θα πρέπει να εφαρμοστεί κατάλληλος μετασχηματισμός, όπως διαφορές πρώτης τάξης ή/και εποχικές διαφορές. Συνεπώς, στη μορφή που βρίσκεται η σειρά δεν είναι κατάλληλη για άμεση εφαρμογή μοντέλου ARMA(p, q). Πρώτα απαιτείται η μετατροπή της σε στάσιμη, και στη συνέχεια η επανεξέταση των διαγραμμάτων αυτοσυσχέτισης για την επιλογή κατάλληλου μοντέλου.

5.4 Έλεγχος Στασιμότητας Πρώτων Εποχικών Διαφορών

Για τη διερεύνηση της στασιμότητας εφαρμόστηκαν πρώτες εποχικές διαφορές ($\text{lag}=12$) στη μηνιαία σειρά βροχόπτωσης του Ζευγολατιού Κορινθίας. Ακολούθησε ανάλυση τόσο με στατιστικά κριτήρια (μέσος όρος, διακύμανση), όσο και με διαγράμματα χρονοσειράς, ACF και PACF.

Στατιστικά Κριτήρια:

- **Μέσοι Όροι ανά Έτος (mm):**

1.61, -14.35, -6.29, -9.35, -10.08, 15.97, 13.38, 3.76, 14.83

Παρατηρείται μεγάλη διακύμανση των μέσων τιμών, με εναλλαγές από θετικές σε αρνητικές τιμές, κάτι που δηλώνει ότι ο μέσος όρος της σειράς δεν παραμένει σταθερός με την πάροδο του χρόνου.


- **Διακυμάνσεις ανά Έτος (mm^2):**

1767.82, 1357.72, 1526, 1070.89, 421.42, 3375.7, 3682.91, 2166.06, 2140.49


Η διακύμανση διαφέρει έντονα από χρονιά σε χρονιά (από 421.42 έως 3682.91), γεγονός που ενισχύει την υπόθεση μη στασιμότητας. Το κριτήριο $\max(\text{vars})/\min(\text{vars}) = 3682.91/421.42 \approx 8.74 > 4$ υποδηλώνει επίσης μη σταθερή διακύμανση.

Γραφική Ανάλυση:

- **Χρονοδιάγραμμα:** Στο Σχήμα 17 παρουσιάζεται το χρονοδιάγραμμα των πρώτων εποχικών διαφορών, το οποίο εμφανίζει έντονες διακυμάνσεις, μεγάλες κορυφώσεις ανά έτος και σημαντικές μεταβολές του μέσου όρου.
- **ACF και PACF:** Τα διαγράμματα ACF και PACF (Σχήμα 18) δείχνουν αργή φθορά (slow decay) των τιμών, καθώς και σημαντικές τιμές σε πολλά lags, κυρίως στα εποχικά lags (π.χ. lag=12). Αυτό αποτελεί χαρακτηριστικό μη στάσιμης σειράς, καθώς σε στάσιμες σειρές το ACF/PACF μηδενίζονται γρήγορα.



Σχήμα 17: Χρονοδιάγραμμα πρώτων εποχικών διαφορών (lag=12) της μηνιαίας βροχόπτωσης.



Σχήμα 18: ACF και PACF πρώτων εποχικών διαφορών της μηνιαίας βροχόπτωσης.

Συμπέρασμα: Η σειρά των πρώτων εποχικών διαφορών ($\text{lag}=12$) **δεν είναι στάσιμη**, καθώς τόσο ο μέσος όσο και η διακύμανση μεταβάλλονται σημαντικά ανά έτος, ενώ το ACF και PACF εμφανίζουν σημαντικές τιμές σε υψηλά lags. Για να επιτευχθεί στασιμότητα, απαιτείται περαιτέρω μετασχηματισμός (π.χ. επιπλέον διαφορές ή κατάλληλος μετασχηματισμός).

5.5 Δυνατότητα Μοντελοποίησης με SARIMA

Σύμφωνα με την ανάλυση της προηγούμενης ενότητας (γ), η σειρά των πρώτων εποχικών διαφορών δεν είναι στάσιμη, καθώς τόσο ο μέσος όσο και η διακύμανση μεταβάλλονται σημαντικά διαχρονικά, ενώ τα διαγράμματα ACF και PACF παρουσιάζουν αργή φθορά και σημαντικές τιμές σε υψηλά lags. Η προϋπόθεση της στασιμότητας αποτελεί βασικό κριτήριο για τη σωστή εφαρμογή μοντέλων χρονοσειρών τύπου ARMA/ARIMA/SARIMA.

Συνεπώς, δεν είναι δυνατή η άμεση προσαρμογή μοντέλου SARIMA στα δεδομένα της αρχικής σειράς, καθώς η βασική υπόθεση της στασιμότητας δεν ικανοποιείται ούτε μετά την εφαρμογή πρώτων εποχικών διαφορών.

Για να είναι εφικτή η μοντελοποίηση με SARIMA, θα πρέπει να δοκιμαστούν περαιτέρω μετασχηματισμοί (όπως δεύτερες διαφορές) ή να εξεταστεί η πιθανότητα ύπαρξης εξωγενών παραγόντων που επιδρούν στη δομή της σειράς.

Συμπέρασμα: Η μη στασιμότητα της σειράς ακόμη και μετά από εποχική διαφοροποίηση αποτελεί ένδειξη περίπλοκης δομής και απαιτεί περαιτέρω στατιστική διερεύνηση πριν την εφαρμογή μοντέλων SARIMA.

5.6 Έλεγχος Στασιμότητας Διπλών Διαφορών (Πρώτες + Εποχικές) στη Μηνιαία Βροχόπτωση

Σύμφωνα με το προηγούμενο ερώτημα (γ), η χρονοσειρά των πρώτων εποχικών διαφορών δεν κρίθηκε στάσιμη. Για τον λόγο αυτό, εφαρμόστηκε **διπλή διαφοροποίηση**.

ηση στη σειρά: πρώτες διαφορές και εποχικές διαφορές ($\text{lag}=12$). Ακολουθεί ανάλυση της νέας χρονοσειράς ως προς τη στασιμότητα, τόσο με γραφική διερεύνηση όσο και με τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF).


Χρονοδιάγραμμα: Στο Σχήμα 19 φαίνεται η σειρά των διπλών διαφορών. Η νέα χρονοσειρά παρουσιάζει διακυμάνσεις γύρω από το μηδέν, χωρίς εμφανή τάση ή έντονες περιοδικές διακυμάνσεις. Ο μέσος και η διακύμανση φαίνεται να παραμένουν σταθεροί με την πάροδο του χρόνου, στοιχείο που υποδηλώνει πιθανή στασιμότητα.




Σχήμα 19: Χρονοδιάγραμμα διπλών διαφορών (πρώτες + εποχικές) της μηνιαίας βροχόπτωσης Ζευγολατιού Κορινθίας.

Ανάλυση ACF και PACF: Στα διαγράμματα αυτοσυσχέτισης (ACF, Σχήμα 20) και μερικής αυτοσυσχέτισης (PACF, Σχήμα 21), παρατηρούνται τα εξής:

- **ACF:** Εμφανίζεται μια σημαντική αρνητική τιμή στο $\text{lag } 1$ (-0.45) και επίσης μια αξιοσημείωτη τιμή στο $\text{lag } 12$ (-0.35), ενώ στα επόμενα lags οι τιμές κινούνται κοντά στο μηδέν. Η γρήγορη αποσύνθεση των συντελεστών υποδηλώνει απουσία μακροχρόνιας αυτοσυσχέτισης, στοιχείο στάσιμης σειράς.
- **PACF:** Η PACF εμφανίζει σημαντικές τιμές στα $\text{lag } 1$ και $\text{lag } 2$, καθώς και αρνητική τιμή στο $\text{lag } 12$. Το γεγονός ότι οι τιμές μειώνονται γρήγορα επιβεβαιώνει επίσης τη στασιμότητα.



Σχήμα 20: ACF διπλών διαφορών (πρώτες + εποχικές) της μηνιαίας βροχόπτωσης.



Σχήμα 21: PACF διπλών διαφορών (πρώτες + εποχικές) της μηνιαίας βροχόπτωσης.

Συμπέρασμα: Η σειρά των διπλών διαφορών (πρώτες + εποχικές) της μηνιαίας βροχόπτωσης εμφανίζει χαρακτηριστικά **στάσιμης χρονοσειράς**, καθώς δεν παρουσιάζει τάση ή εποχικότητα, ενώ οι τιμές των ACF/PACF αποσυντίθενται γρήγορα και δεν υπάρχουν ισχυρές αυτοσυσχετίσεις σε υψηλά lags.

5.7 Προσαρμογή και Έλεγχος Μοντέλου SARIMA

Με βάση τα προηγούμενα ευρήματα στασιμότητας, εφαρμόστηκε το μοντέλο $SARIMA(2, 1, 1)(1, 1, 1)_{12}$ στη μηνιαία σειρά βροχόπτωσης Ζευγολατιού Κορινθίας για τα έτη 2016--2025. Το μοντέλο περιλαμβάνει πρώτες διαφορές ($d = 1$), πρώτες εποχικές διαφορές ($D = 1$) και εποχικότητα 12 μηνών.

Παράμετροι Εκτιμηθέντος Μοντέλου:


- $AR(1)$: -0.003
- $AR(2)$: -0.085
- $MA(1)$: -0.877
- $SAR(1)$: 0.136
- $SMA(1)$: -1.00

Στατιστικά Μοντέλου:

- AIC : 1030.77
- log-likelihood: -509.39


Διαγνωστικός Έλεγχος Καταλοίπων:

Για να ελεγχθεί η επάρκεια του μοντέλου SARIMA, αναλύθηκαν τα κατάλοιπα (residuals) ως προς τη στασιμότητα, την αυτοσυσχέτιση και την κανονικότητα.



Σχήμα 22: Διαγράμματα αυτοσυσχέτισης (ACF, αριστερά) και μερικής αυτοσυσχέτισης (PACF, δεξιά) των καταλοίπων του μοντέλου SARIMA.

Τα διαγράμματα ACF και PACF των καταλοίπων δείχνουν ότι όλες οι τιμές βρίσκονται εντός των διαστημάτων εμπιστοσύνης, δεν υπάρχει σημαντική αυτοσυσχέτιση, και τα κατάλοιπα μπορούν να θεωρηθούν λευκός θόρυβος.



Σχήμα 23: Ιστόγραμμα καταλοίπων του μοντέλου SARIMA. Η κατανομή πλησιάζει την κανονική, με ελαφρά ασυμμετρία.


Έλεγχος Ljung-Box: Για τα κατάλοιπα του μοντέλου, ο έλεγχος Ljung-Box (lag=24) δίνει:

$$X^2 = 17.22, p\text{-value} = 0.839$$

Εφόσον το p -value είναι πολύ μεγαλύτερο του 0.05, **δεν απορρίπτεται η μηδενική υπόθεση της ανεξαρτησίας των καταλοίπων**. Τα κατάλοιπα του μοντέλου δεν παρουσιάζουν στατιστικά σημαντική αυτοσυσχέτιση.

Πρόβλεψη Μηνιαίας Βροχόπτωσης:

Χρησιμοποιώντας το εκτιμημένο μοντέλο SARIMA, πραγματοποιήθηκε πρόβλεψη της μηνιαίας βροχόπτωσης για τους επόμενους 12 μήνες. Το Σχήμα 24 παρουσιάζει τις παρατηρήσεις, τις προβλεπόμενες τιμές καθώς και τα 95% διαστήματα εμπιστοσύνης.



Σχήμα 24: Πρόβλεψη μηνιαίας βροχόπτωσης για τους επόμενους 12 μήνες με το μοντέλο SARIMA. Η μαύρη γραμμή είναι οι πραγματικές παρατηρήσεις, η κόκκινη οι προβλέψεις και οι μπλε διακεκομμένες γραμμές το 95% διάστημα εμπιστοσύνης.

Σχολιασμός: Το μοντέλο $SARIMA(2, 1, 1)(1, 1, 1)_{12}$ προσαρμόστηκε επιτυχώς στα δεδομένα, παρουσιάζοντας ικανοποιητική ερμηνεία της δυναμικής της σειράς. Η πρόβλεψη εμφανίζει εποχικά μοτίβα και ρεαλιστικά διαστήματα αβεβαιότητας. Τα διαστήματα εμπιστοσύνης αυξάνονται όσο απομακρυνόμαστε στο μέλλον, γεγονός που αντανακλά τη φυσιολογική αύξηση της αβεβαιότητας στις μακροπρόθεσμες προβλέψεις.


Συμπέρασμα: Το μοντέλο $SARIMA(2, 1, 1)(1, 1, 1)_{12}$ παρέχει αξιόπιστη πρόβλεψη για τη μηνιαία βροχόπτωση, με καλή συμπεριφορά καταλοίπων και συνεπή στατιστικά.

5.8 Έφαρμογή και σύγκριση διευρυμένων μοντέλων

Η επάρκεια του τελικού μοντέλου $SARIMA(2, 1, 1)(1, 1, 1)_{12}$ για τη μηνιαία βροχόπτωση ελέγχθηκε συστηματικά με δύο τρόπους: (I) αναλυτικό έλεγχο των καταλοίπων και (II) σύγκριση με διευρυμένα μοντέλα ευρύτερης τάξης.

(I) Διαγνωστικός Έλεγχος Καταλοίπων

- **Διαγράμματα ACF/PACF:** Τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) των καταλοίπων του μοντέλου (Σχήμα 22) δείχνουν ότι όλες οι τιμές βρίσκονται εντός των ορίων εμπιστοσύνης, χωρίς σημαντικές αιχμές στα εποχικά lags. Αυτό υποδεικνύει ότι τα κατάλοιπα προσεγγίζουν λευκό θόρυβο.
- **Q-Q plot:** Το διάγραμμα Q-Q (Σχήμα 25) παρουσιάζει καλή προσέγγιση στην ευθεία, με μικρές αποκλίσεις στις άκρες, χαρακτηριστικό ανεκτό για υδρολογικά δεδομένα.
- **Έλεγχος Ljung-Box:** Ο έλεγχος Ljung-Box για $lag=24$ έδωσε $p\text{-value} = 0.839$ (δηλ. > 0.05), επομένως δεν απορρίπτεται η υπόθεση του λευκού θορύβου στα κατάλοιπα.



Σχήμα 25: Q-Q plot των καταλοίπων του μοντέλου SARIMA. Η κατανομή πλησιάζει την κανονική, χωρίς έντονη ασυμμετρία ή βαριές ουρές.

(II) Σύγκριση με Διευρυμένα Μοντέλα

Για να ελεγχθεί αν ένα πιο πολύπλοκο μοντέλο θα είχε καλύτερη συμπεριφορά, προσαρμόστηκαν και τα παρακάτω διευρυμένα μοντέλα:

- SARIMA(3, 1, 1)(1, 1, 1)₁₂
- SARIMA(2, 1, 2)(1, 1, 1)₁₂
- SARIMA(2, 1, 1)(2, 1, 1)₁₂
- SARIMA(2, 1, 1)(1, 1, 2)₁₂
- SARIMA(3, 1, 2)(2, 1, 2)₁₂

Τα αποτελέσματα (AIC, Ljung-Box test) συνοψίζονται στον Πίνακα 4.

Πίνακας 4: Σύγκριση δεικτών επάρκειας μεταξύ του βασικού και των διευρυμένων μοντέλων SARIMA

Προδιαγραφή Μοντέλου	AIC	ΔAIC	Ljung-Box p-value
SARIMA(2,1,1)(1,1,1) ₁₂	1030.77	0.000	0.839
SARIMA(2,1,1)(1,1,2) ₁₂	1031.03	+0.26	0.742
SARIMA(3,1,1)(1,1,1) ₁₂	1031.26	+0.48	0.681
SARIMA(3,1,2)(2,1,2) ₁₂	1032.07	+1.30	0.598
SARIMA(2,1,1)(2,1,1) ₁₂	1032.62	+1.85	0.553
SARIMA(2,1,2)(1,1,1) ₁₂	1032.99	+2.22	0.512

Συμπεράσματα:

- Το αρχικό μοντέλο SARIMA(2, 1, 1)(1, 1, 1)₁₂ είχε το ελάχιστο AIC και τα πιο «λευκά» κατάλοιπα (υψηλότερο p-value στο Ljung-Box).


- Κανένα από τα διευρυμένα μοντέλα δεν παρουσίασε σημαντική βελτίωση (όλα είχαν $\Delta AIC < 2$).
- Οι διαγνωστικοί έλεγχοι υποδεικνύουν ότι η προσθήκη επιπλέον παραμέτρων οδηγεί σε υπερπροσαρμογή, χωρίς ουσιαστικό όφελος.

Τελική Εκτίμηση:

Το μοντέλο SARIMA(2, 1, 1)(1, 1, 1)₁₂ θεωρείται πλήρως επαρκές και κατάλληλο για επιχειρησιακή πρόγνωση της μηνιαίας βροχόπτωσης. Το μοντέλο διατηρεί παραμετρική απλότητα και στατιστική αξιοπιστία, ενώ αντανakλά αποτελεσματικά τη δυναμική της χρονοσειράς βροχοπτώσεων.

5.9 Πρόβλεψη Μηνιαίας Βροχόπτωσης για τα Επόμενα Δύο Έτη


Με το τελικό μοντέλο SARIMA(2, 1, 1)(1, 1, 1)₁₂ πραγματοποιήθηκε πρόβλεψη της μηνιαίας βροχόπτωσης για τα δύο επόμενα έτη (2025--2027). Τα αποτελέσματα συνοψίζονται στα παρακάτω διαγράμματα και πίνακες.



Σχήμα 26: Πρόβλεψη μηνιαίας βροχόπτωσης για τα επόμενα δύο έτη με το μοντέλο SARIMA. Η μαύρη γραμμή είναι τα ιστορικά δεδομένα, η κόκκινη η πρόβλεψη, οι μπλε διακεκομμένες γραμμές τα 95% διαστήματα εμπιστοσύνης και η πράσινη κάθετη γραμμή το σημείο έναρξης της πρόβλεψης.

Αξιολόγηση της Πρόβλεψης:


- **Εποχικότητα και μεταβλητότητα:** Οι προβλέψεις ακολουθούν τα εποχικά μοτίβα της ιστορικής βροχόπτωσης, με διακυμάνσεις ανάλογες των προηγούμενων ετών.
- **Διαστήματα εμπιστοσύνης:** Τα διαστήματα εμπιστοσύνης διευρύνονται όσο απομακρυνόμαστε στο μέλλον, γεγονός που αντανakλά την αυξανόμενη αβεβαιότητα των προβλέψεων.
- **Σύγκριση με ιστορικά δεδομένα:** Παρατηρείται ότι οι προβλεπόμενες τιμές εμφανίζουν υψηλότερο μέσο όρο βροχόπτωσης συγκριτικά με το ιστορικό μέσο όρο.




Σχήμα 27: Σύγκριση μέσου όρου ετήσιας βροχόπτωσης της πρόβλεψης με τον ιστορικό μέσο όρο.

Έτος Πρόβλεψης	Μέσος Όρος Πρόβλεψης (mm)	Ποσοστιαία Διαφορά από Ιστορικό Μέσο Όρο
Πρώτο Έτος	---	+56.6%
Δεύτερο Έτος	---	+60.7%

Πίνακας 5: Ποσοστιαία διαφορά ετήσιου μέσου όρου πρόβλεψης ως προς τον ιστορικό μέσο όρο για τα δύο έτη πρόβλεψης.




Σχήμα 28: Σύγκριση πραγματικών (μαύρη γραμμή) και προβλεπόμενων (κόκκινη γραμμή) τιμών βροχόπτωσης για την περίοδο ελέγχου.



Σχήμα 29: Σύγκριση μηνιαίων προβλέψεων ανά έτος με το ιστορικό μέσο όρο (μπλε γραμμή).

Σύγκριση Πραγματικών και Προβλεπόμενων Τιμών:



Σχήμα 30: Διάγραμμα αυτοσυσχέτισης (ACF) των σφαλμάτων πρόβλεψης. Όλες οι τιμές εντός διαστημάτων εμπιστοσύνης, χωρίς σημαντική αυτοσυσχέτιση.

Διαγνωστικοί Έλεγχοι Προβλέψεων:

Συμπεράσματα:

- Οι προβλέψεις του μοντέλου διατηρούν τη δυναμική και την εποχικότητα της χρονοσειράς, παρουσιάζοντας ρεαλιστικά και σταθερά διαστήματα τιμών για τα δύο επόμενα έτη.
- Ο μέσος όρος της προβλεπόμενης βροχόπτωσης εμφανίζεται σημαντικά υψηλότερος (κατά περίπου 57-61%) από τον ιστορικό μέσο όρο, υποδεικνύοντας πιθανή αλλαγή στην κλιματική συμπεριφορά ή επίδραση εξωγενών παραγόντων.
- Τα διαστήματα εμπιστοσύνης είναι ευρέως διαδεδομένα στα μακροπρόθεσμα διαστήματα, κάτι που καθιστά επιτακτική τη συνεχή επικαιροποίηση του μοντέλου με νέα δεδομένα.

Τελικό σχόλιο: Η μακροπρόθεσμη πρόβλεψη είναι χρήσιμη ως ένδειξη τάσεων, ωστόσο η αβεβαιότητα παραμένει υψηλή λόγω της φύσης των βροχοπτώτικών χρονοσειρών και της εγγενούς μεταβλητότητας του κλίματος.

6 Άσκηση 3: Ανάλυση σε `cmort`, `globtemp` και πωλήσεις μπίρας

6.1 Περιγραφή και Μοντελοποίηση της Χρονοσειράς Εβδομαδιαίας Θνησιμότητας `cmort`

6.1.1 Περιγραφή των Δεδομένων `cmort`

Η χρονοσειρά `cmort` αναφέρεται στην εβδομαδιαία θνησιμότητα (συνολικοί θάνατοι ανά εβδομάδα) στις Ηνωμένες Πολιτείες και αποτελείται από εβδομαδιαίες παρατηρήσεις που καλύπτουν την περίοδο 1970–1979. Τα δεδομένα αυτά συχνά χρησιμοποιούνται ως παράδειγμα στην ανάλυση χρονοσειρών για την εκμάθηση μοντέλων πρόβλεψης, εποχικότητας και αυτοσυσχέτισης.

Τα δεδομένα `cmort` περιλαμβάνουν 508 διαδοχικές εβδομαδιαίες τιμές, οι οποίες καταγράφουν τον αριθμό θανάτων (όλων των αιτίων) στην περιοχή του Λος Άντζελες. Η σειρά αυτή παρουσιάζει εποχικότητα, διακυμάνσεις που σχετίζονται με ιώσεις (π.χ. γρίπη), καθώς και πιθανή τάση μακροπρόθεσμα.

Τα δεδομένα προέρχονται από τη δημοφιλή βάση του πακέτου `astsa` της γλώσσας R και περιγράφονται εκτενώς στη βιβλιογραφία της ανάλυσης χρονοσειρών [11].

Τα δεδομένα `cmort` είναι ευρέως διαδεδομένα σε βιβλία και πανεπιστημιακά συγγράμματα ως τυπικό παράδειγμα ανάλυσης χρονοσειρών με αυτοπαλίνδρομα και κινούμενου μέσου μοντέλα.

6.1.2 Προσαρμογή AR(2) Μοντέλου στη Χρονοσειρά `cmort` και Βραχυπρόθεσμη Πρόβλεψη

Η χρονοσειρά `cmort` (εβδομαδιαία θνησιμότητα) προσαρμόστηκε σε μοντέλο αυτοπαλινδρόμησης δεύτερης τάξης (AR(2)), με τη μέθοδο της γραμμικής παλινδρόμησης. Ο γενικός τύπος του μοντέλου είναι:

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \epsilon_t$$

όπου ϵ_t λευκός θόρυβος.

Εκτίμηση Μοντέλου: Με τη μέθοδο των ελαχίστων τετραγώνων, το προσαρμοσμένο μοντέλο AR(2) έχει τη μορφή:


$$\hat{x}_t = \hat{\phi}_1 x_{t-1} + \hat{\phi}_2 x_{t-2}$$

και τα εκτιμημένα κατάλοιπα ορίστηκαν ως $\hat{\epsilon}_t = x_t - \hat{x}_t$.


Διαγνωστικοί Έλεγχοι:

- **ACF/PACF Καταλοίπων:** Τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) των καταλοίπων (Figure 31) δείχνουν ότι όλες οι τιμές βρίσκονται εντός των ορίων εμπιστοσύνης, άρα τα κατάλοιπα αποτελούν λευκό θόρυβο.

- **Έλεγχος Ljung-Box:** Για $lag = 10$ και $lag = 20$ έχουμε p -values 0.6141 και 0.3902 αντίστοιχα, άρα δεν απορρίπτεται η μηδενική υπόθεση ανεξαρτησίας (λευκός θόρυβος).
- **Οπτική Εξέταση Καταλοίπων:** Τα κατάλοιπα εμφανίζουν μηδενικό μέσο όρο, σταθερή διακύμανση και καμία εμφανή δομή (Figure 32).



Σχήμα 31: Διαγράμματα ACF (αριστερά) και PACF (δεξιά) των καταλοίπων του AR(2) μοντέλου.




Σχήμα 32: Χρονοδιάγραμμα καταλοίπων του AR(2) μοντέλου.

Μέτρα Ακρίβειας Μοντέλου:

- Μέση Τετραγωνική Απόκλιση (MSE): 32.32
- Ριζική Μέση Τετραγωνική Απόκλιση (RMSE): 5.68
- Μέσο Απόλυτο Σφάλμα (MAE): 4.48

Βραχυπρόθεσμη Πρόβλεψη και 95% Διάστημα Εμπιστοσύνης: Με το εκτιμημένο μοντέλο πραγματοποιήθηκε πρόβλεψη της θνησιμότητας για 4 επόμενες εβδομάδες. Το διάγραμμα 33 απεικονίζει τις προβλεπόμενες τιμές και τα 95% διαστήματα εμπιστοσύνης:



Σχήμα 33: Πρόβλεψη θνησιμότητας για 4 βδομάδες με AR(2) και 95% διαστήματα εμπιστοσύνης (πράσινες γραμμές).

Συμπεράσματα:

- Το AR(2) μοντέλο περιγράφει ικανοποιητικά τη δομή της χρονοσειράς `smort`, με τα κατάλοιπα να εμφανίζουν χαρακτηριστικά λευκού θορύβου.
- Η πρόβλεψη για τις 4 επόμενες εβδομάδες θεωρείται αξιόπιστη εντός του δοσμένου διαστήματος εμπιστοσύνης.
- Τα διαστήματα εμπιστοσύνης είναι σχετικά μεγάλα, γεγονός που αντανακλά τη φυσιολογική αβεβαιότητα στην πρόβλεψη της θνησιμότητας.
- Για πιο ακραίες διακυμάνσεις ή ασυνήθιστα επεισόδια θνησιμότητας, το απλό μοντέλο AR(2) ίσως δεν επαρκεί.

6.2 Ανάλυση και Πρόβλεψη Χρονοσειράς Παγκόσμιας Θερμοκρασίας Ξηράς με ARIMA


6.2.1 Περιγραφή της Χρονοσειράς Παγκόσμιας Θερμοκρασίας Ξηράς (`globtemp`)

Η χρονοσειρά `globtemp` περιλαμβάνει ετήσιες μετρήσεις των παγκόσμιων ανωμاليών θερμοκρασίας ξηράς για την περίοδο 1850--2023. Τα δεδομένα προέρχονται από διεθνείς βάσεις κλιματικών δεδομένων και συνιστούν έναν από τους σημαντικότερους δείκτες για τη μελέτη των μακροχρόνιων τάσεων στη θερμοκρασία της γης, σε συνάρτηση με την κλιματική αλλαγή. Συγκεκριμένα, η `globtemp` καταγράφει τη διαφορά της μέσης θερμοκρασίας κάθε έτους από μία προκαθορισμένη μέση τιμή αναφοράς (*climatological baseline*), επιτρέποντας έτσι τη σύγκριση διαφορετικών περιόδων και τον εντοπισμό μακροπρόθεσμων μεταβολών στη θερμοκρασία [2, 7].

Οι χρονοσειρές παγκόσμιας θερμοκρασίας χρησιμοποιούνται ευρέως στη στατιστική και την οικονομετρία του κλίματος, για την ανάλυση τάσεων, ανωμαλιών και την πρόβλεψη μελλοντικών τιμών [8]. Η ανάλυση τέτοιων σειρών απαιτεί τον έλεγχο στασιμότητας, την απομάκρυνση της τάσης και την επιλογή κατάλληλων στοχαστικών μοντέλων (όπως ARIMA), ώστε να διασφαλιστεί η εγκυρότητα των στατιστικών συμπερασμάτων.


6.2.2 Προκαταρκτική Ανάλυση και Στασιμότητα

Αρχικά εξετάστηκε η χρονοσειρά `globtemp`, η οποία περιλαμβάνει ετήσια δεδομένα παγκόσμιας θερμοκρασίας ξηράς για τα έτη 1850–2023. Παρατηρήθηκε εμφανής τάση ανόδου στη θερμοκρασία, γεγονός που επιβεβαιώθηκε από το διάγραμμα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF) της αρχικής σειράς, όπου οι τιμές φθίνουν αργά, υποδεικνύοντας μη στασιμότητα (Σχήμα 34).




Σχήμα 34: ACF και PACF αρχικής χρονοσειράς `globtemp`.

Για να επιτευχθεί στασιμότητα, υπολογίστηκε η πρώτη διαφορά της σειράς, η οποία απεικονίζεται στο Σχήμα 35. Όπως φαίνεται και από τα αντίστοιχα διαγράμματα ACF και PACF (Σχήμα 36), η διαφοροποιημένη σειρά παρουσιάζει πλέον χαρακτηριστικά στασιμότητας.



Σχήμα 35: 1η διαφορά της χρονοσειράς `globtemp`.



Σχήμα 36: ACF και PACF της 1ης διαφοράς της σειράς globtemp.

6.2.3 Επιλογή Κατάλληλου Μοντέλου ARIMA

Δοκιμάστηκαν διάφορα μοντέλα ARIMA με μία διαφορά ($d = 1$). Η επιλογή έγινε με βάση το κριτήριο Akaike (AIC):

Μοντέλο	d	Συντελεστές	AIC
ARIMA(1,1,0)	1	ar1 = -0.065	152.72
ARIMA(1,1,1)	1	ar1 = -0.066, ma1 = -0.73	120.64
ARIMA(2,1,1)	1	ar1, ar2, ma1	122.58


Πίνακας 6: Σύγκριση μοντέλων ARIMA και AIC.

Το βέλτιστο μοντέλο είναι το ARIMA(1,1,1), το οποίο παρουσιάζει το χαμηλότερο AIC.


6.2.4 Διαγνωστικός Έλεγχος Μοντέλου

Τα διαγνωστικά του μοντέλου ARIMA(1,1,1) περιλαμβάνουν ανάλυση των υπολοίπων για κανονικότητα και αυτοσυσχέτιση:


- **Ιστόγραμμα Υπολοίπων:** Τα υπόλοιπα είναι συμμετρικά και περίπου κανονικά (Σχήμα 37).
- **Q-Q Plot:** Τα σημεία ευθυγραμμίζονται με την ευθεία κανονικής κατανομής (Σχήμα 38).
- **ACF Υπολοίπων:** Δεν παρατηρείται σημαντική αυτοσυσχέτιση.
- **Ljung-Box Test:** Το p -value είναι > 0.05 , δηλαδή τα υπόλοιπα είναι λευκός θόρυβος.



Σχήμα 37: Ιστόγραμμα υπολοίπων του μοντέλου ARIMA(1,1,1).




Σχήμα 38: Q-Q Plot υπολοίπων ARIMA(1,1,1).



Σχήμα 39: Υπόλοιπα του μοντέλου ARIMA(1,1,1) ανά έτος.

6.2.5 Πρόβλεψη για τα Επόμενα 10 Χρόνια

Με το τελικό μοντέλο ARIMA(1,1,1) πραγματοποιήθηκε πρόβλεψη για τα έτη 2024–2033. Το διάστημα εμπιστοσύνης 95% υπολογίστηκε και οπτικοποιήθηκε στο Σχήμα 40.



Σχήμα 40: Πρόβλεψη παγκόσμιας θερμοκρασίας ξηράς με $ARIMA(1,1,1)$ για τα επόμενα 10 έτη (κόκκινη γραμμή: πρόβλεψη, πράσινο: 95% διάστημα εμπιστοσύνης).

6.2.6 Συμπεράσματα

- Η χρονοσειρά παρουσίαζε μη στασιμότητα, η οποία αποκαταστάθηκε με πρώτη διαφορά.
- Το μοντέλο $ARIMA(1,1,1)$ κρίθηκε ως το βέλτιστο με βάση το AIC.
- Τα υπολείμματα του μοντέλου δεν παρουσιάζουν σημαντική αυτοσυσχέτιση και είναι περίπου κανονικά κατανομημένα.
- Η πρόβλεψη για τα επόμενα 10 χρόνια εμφανίζει σταθεροποιημένη μέση τιμή, αλλά με σημαντική αβεβαιότητα, όπως φαίνεται από τα ευρέα διαστήματα εμπιστοσύνης.

Συνολικά, το μοντέλο $ARIMA(1,1,1)$ μπορεί να χρησιμοποιηθεί για βραχυπρόθεσμη και μεσοπρόθεσμη πρόβλεψη της παγκόσμιας θερμοκρασίας ξηράς, αλλά απαιτείται προσοχή στη διαχείριση της αβεβαιότητας των προβλέψεων.

6.3 Ανάλυση Εποχικότητας, Τάσης και Κυκλικής Μεταβολής Πωλήσεων Μπίρας (2016--2019)


Τα δεδομένα του πίνακα παρουσιάζουν τις πωλήσεις μπίρας μίας βιομηχανίας (σε εκατομμύρια μπουκάλια) ανά εποχή από το 2016 έως το 2019.

Έτος	Χειμώνας	Άνοιξη	Καλοκαίρι	Φθινόπωρο
2016	1	3	6	4
2017	2	2	7	5
2018	2	4	8	5
2019	1	3	8	6

Πίνακας 7: Πωλήσεις μπίρας (εκατομμύρια μπουκάλια) ανά εποχή και έτος.

6.3.1 Εξάλειψη Εποχικότητας και Εποχιακοί Δείκτες

Αρχικά τα δεδομένα μετατράπηκαν σε χρονοσειρά με συχνότητα 4 (εποχές ανά έτος) και έγινε αποσύνθεση με το πολυπλασιαστικό μοντέλο. Οι εποχιακοί δείκτες εκφράζουν πόσο κάθε εποχή διαφοροποιεί τις πωλήσεις από τον ετήσιο μέσο όρο.




Σχήμα 41: Διάγραμμα εποχικών δεικτών. Οι πωλήσεις αυξάνονται σημαντικά το Καλοκαίρι και μειώνονται τον Χειμώνα.

Ερμηνεία: Οι εποχιακοί δείκτες δείχνουν ότι το Καλοκαίρι (δείκτης > 1) σημειώνονται οι υψηλότερες πωλήσεις, ενώ τον Χειμώνα (< 1) οι χαμηλότερες -- αναμενόμενο για το συγκεκριμένο προϊόν.

6.3.2 Γραμμή Τάσης (Trend Line)

Μετά την αποεποχικοποίηση, εφαρμόστηκε γραμμική παλινδρόμηση για τη γραμμή τάσης, ώστε να αποτυπωθεί η γενική κατεύθυνση των πωλήσεων χωρίς την επίδραση της εποχικότητας.




Σχήμα 42: Γραμμή τάσης πωλήσεων (πράσινη γραμμή) και αποεποχικοποιημένες πωλήσεις (κόκκινη γραμμή).

Ερμηνεία: Η γραμμή τάσης παρουσιάζει μικρή αύξηση, υποδηλώνοντας αργή αλλά σταθερή άνοδο της ζήτησης, αφού αφαιρεθεί η εποχικότητα.

6.3.3 Κυκλική Μεταβολή


Η κυκλική μεταβολή προσδιορίστηκε με τη μέθοδο των σχετικών κυκλικών καταλοίπων, δηλαδή ως ο λόγος των αποεποχικοποιημένων πωλήσεων προς τη γραμμή τάσης.



Σχήμα 43: Διάγραμμα κυκλικής μεταβολής (σχετικά κυκλικά κατάλοιπα).

Ερμηνεία: Οι τιμές κυμαίνονται γύρω από το 1, υποδεικνύοντας ότι δεν υπάρχουν έντονες κυκλικές επιδράσεις (δηλαδή επιπλέον διακυμάνσεις πέραν της εποχικότητας και της τάσης).

6.3.4 Χρονοσειρά Πρωτογενών Πωλήσεων



Σχήμα 44: Χρονοσειρά αρχικών (πρωτογενών) πωλήσεων πριν την επεξεργασία.

Συμπέρασμα:

- Υπάρχει έντονη εποχικότητα με σημαντική αύξηση πωλήσεων το Καλοκαίρι.
- Η γραμμή τάσης δείχνει οριακά αυξητική πορεία των πωλήσεων στη διάρκεια των ετών.
- Η κυκλική συνιστώσα δεν παρουσιάζει σημαντικές αποκλίσεις, άρα δεν εντοπίζονται έντονες κυκλικές επιδράσεις.

7 Γενικά Συμπεράσματα

Στην παρούσα εργασία αναλύθηκαν πέντε διαφορετικές πραγματικές χρονοσειρές με στόχο την κατανόηση των χαρακτηριστικών τους και την αξιόπιστη πρόβλεψη μελλοντικών τιμών μέσω κατάλληλων μοντέλων χρονοσειρών.

Τα βασικά συμπεράσματα που προέκυψαν είναι τα εξής:

- Για τα δεδομένα της παγκόσμιας θερμοκρασίας ξηράς, το μοντέλο **ARIMA(1,1,1)** απέδωσε την καλύτερη προσαρμογή, σύμφωνα με τα κριτήρια AIC/BIC και τα διαγνωστικά τεστ, ενώ τα διαστήματα εμπιστοσύνης των προβλέψεων ήταν σχετικά ευρεία, αντανακλώντας την αβεβαιότητα της μακροχρόνιας πρόβλεψης.
- Στη χρονοσειρά της εβδομαδιαίας θνησιμότητας (*cmort*), το μοντέλο **AR(2)** περιέγραψε ικανοποιητικά τη δομή των δεδομένων, με τα υπολείμματα να συμπεριφέρονται ως λευκός θόρυβος.
- Για τη μηνιαία βροχόπτωση Ζευγολατιού και το μηνιαίο ποσοστό ανεργίας Ισπανίας, εφαρμόστηκαν κατάλληλα μοντέλα SARIMA, τα οποία ανέδειξαν τόσο την εποχικότητα όσο και τη μακροχρόνια τάση των δεδομένων.
- Στη χρονοσειρά πωλήσεων μπύρας, η ανάλυση εποχικότητας, τάσης και κυκλικής μεταβολής αποκάλυψε έντονες περιοδικές διακυμάνσεις, με το καλοκαίρι να παρουσιάζει σημαντική αύξηση πωλήσεων.
- Συνολικά, η ανάλυση των χρονοσειρών ανέδειξε τη σημασία της προσεκτικής στατιστικής διερεύνησης (έλεγχος στασιμότητας, διάγνωση υπολοίπων) και της επιλογής του κατάλληλου μοντέλου για τη βελτιστοποίηση των προβλέψεων.

Τα αποτελέσματα καταδεικνύουν πως η συστηματική ανάλυση και η κατάλληλη μοντελοποίηση μπορούν να προσφέρουν χρήσιμες προβλέψεις και να βοηθήσουν στη λήψη αποφάσεων σε διάφορα πεδία (κλίμα, υγεία, αγορά εργασίας, κ.ά.).

Αναφορές

- [1] George E. P. Box κ.ά. *Time Series Analysis: Forecasting and Control*. Wiley, 2016.
- [2] P. Brohan κ.ά. "Uncertainty estimates in regional and global observed temperature changes: A new dataset from 1850". Στο: *Journal of Geophysical Research: Atmospheres* 111.D12 (2006), σ. D12106.
- [3] Chris Chatfield. *The Analysis of Time Series: An Introduction*. Chapman και Hall/CRC, 2016.
- [4] Instituto Nacional de Estadística (INE). *Labor market statistics*. Ημερομηνία πρόσβασης: 25 Ιουνίου 2025. 2024. URL: <https://www.ine.es/>.
- [5] Eurostat. *Unemployment statistics*. Ημερομηνία πρόσβασης: 25 Ιουνίου 2025. 2024. URL: https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Unemployment_statistics.
- [6] Rob J Hyndman και George Athanasopoulos. *Forecasting: principles and practice*. 2η έκδοση. <https://otexts.com/fpp2/>. OTexts, 2018.
- [7] P.D. Jones και I. Harris. "Uncertainty in global temperature records". Στο: *Science* 338 (2012), σσ. 617–618.
- [8] H.R. Künsch. "The jackknife and the bootstrap for general stationary observations". Στο: *The Annals of Statistics* 17.3 (1989), σσ. 1217–1241.
- [9] *Open-Meteo: Free Weather API*. Ανάκτηση: Ιούνιος 2024. 2024. URL: <https://open-meteo.com/>.
- [10] Robert H. Shumway και David S. Stoffer. *Time Series Analysis and Its Applications*. Springer, 2017.
- [11] Robert H. Shumway και David S. Stoffer. *Time Series Analysis and Its Applications: With R Examples*. 4η έκδοση. Springer, 2017.

A□ Παραρτήματα

A□.1 Κώδικας Υλοποίησης

Ο παρακάτω κώδικας σε R χρησιμοποιήθηκε για την ανάλυση της χρονοσειράς ανεργίας Ισπανίας:

Listing 1: R code for Spanish Unemployment Analysis

```
1 # 1.a
2 # Creation of a time series
3 unemployment <- c(13.6, 13.8, 13.8, 13.1, 12.5, 12.4, 12.4, 12.8,
4                   13.0, 13.0, 13.0, 13.0,
5                   13.6, 13.6, 13.0, 12.1, 11.6, 11.4, 11.7, 11.9,
6                   12.1, 11.9, 11.7, 11.7,
7                   12.3, 12.4, 12.2, 11.6, 11.2, 11.1, 11.2, 11.3,
8                   11.1, 10.8, 10.5, 10.6,
9                   11.2, 11.5, 11.5, 10.9)
```



```

8 # Creation of object time series
9 unemp_ts <- ts(unemployment, start = c(2022, 1), frequency = 12)
10
11 # 1. Timeline
12 plot(unemp_ts,
13      main = "Unemployment Rate in Spain (Jan. 2022 - Apr. 2025)",
14      xlab = "Year",
15      ylab = "Percentage (%)",
16      col = "darkred",
17      lwd = 2,
18      ylim = c(10, 15))
19 grid(col = "gray", lty = "dotted")
20
21 # 2. Check of stationary series
22 # Calculation of first differences
23 diff_unemp <- diff(unemp_ts)
24
25 # Graph of first differences
26 plot(diff_unemp,
27      main = "First Differences (Stagnation Index)",
28      xlab = "Year",
29      ylab = "Difference",
30      col = "darkblue",
31      lwd = 2)
32 grid(col = "gray", lty = "dotted")
33 abline(h = 0, col = "red", lty = 2)
34
35 # 3. Seasonality analysis
36 decomp <- decompose(unemp_ts)
37
38 # Graphical representation of decomposition
39 par(mfrow = c(4, 1), mar = c(3, 4, 2, 2))
40 plot(decomp$trend, main = "Trend", col = "darkgreen", lwd = 2)
41 plot(decomp$seasonal, main = "Seasonality", col = "darkblue", lwd =
42      2)
43 plot(decomp$random, main = "Random Element", col = "purple", lwd = 2)
44 plot(unemp_ts, main = "Real Series", col = "darkred", lwd = 2)
45 par(mfrow = c(1, 1))
46
47 # 4. Εποχικότητα - boxplot ανά μήνα
48 months <- factor(cycle(unemp_ts),
49                  levels = 1:12,
50                  labels = c("Jan", "Feb", "Mar", "Apr", "May", "Jun",
51                             "Jul", "Aug", "Sep", "Oct", "Nov", "Dec")
52                  )
53
54 boxplot(unemp_ts ~ months,
55        main = "Seasonal Unemployment Pattern (By Month)",
56        xlab = "Month",
57        ylab = "Unemployment Percentage (%)",
58        col = "lightblue",

```

```

57         border = "darkblue")
58 grid(nx = NA, ny = NULL, col = "gray", lty = "dotted")
59
60 # 5. Autocorrelation (ACF) for seasonality
61 acf(unemp_ts,
62     main = "Autocorrelation Function (ACF)",
63     lag.max = 36,
64     col = "darkred",
65     lwd = 2)
66 grid(col = "gray", lty = "dotted")
67
68 # 1.b
69 # First difference application
70 diff_unemp <- diff(unemp_ts)
71
72 # Graph of first differences
73 plot(diff_unemp,
74     main = "First Differences of Unemployment (Stationary Series)",
75     xlab = "Year",
76     ylab = "Difference",
77     col = "darkblue",
78     lwd = 2)
79 abline(h = 0, col = "red", lty = 2)
80 grid(col = "gray", lty = "dotted")
81
82 # Autocorrelation Functions (ACF) and Partial Autocorrelation
    Functions (PACF)
83 par(mfrow = c(1, 2))
84
85 # ACF
86 acf(diff_unemp,
87     lag.max = 24,
88     main = "ACF: First Differences",
89     col = "darkred",
90     lwd = 2)
91
92 # PACF
93 pacf(diff_unemp,
94     lag.max = 24,
95     main = "PACF: First Differences",
96     col = "darkgreen",
97     lwd = 2)
98 par(mfrow = c(1, 1))
99
100 # Προσαρμογή μοντέλων
101 arma21 <- arima(diff_unemp, order = c(2, 0, 1)) # ARMA(2,1) for the
    differences
102 arma11 <- arima(diff_unemp, order = c(1, 0, 1)) # ARMA(1,1) for the
    differences
103
104 # Summary of models

```

```

105 cat("Summary ARMA(2,1):\n")
106 print(summary(arma21))
107
108 cat("\nSummary ARMA(1,1):\n")
109 print(summary(arma11))
110
111 # Balance check
112 check_residuals <- function(model) {
113   par(mfrow = c(1, 2))
114   acf(residuals(model), main = "ACF Residuals", col = "purple")
115   pacf(residuals(model), main = "PACF Residuals", col = "orange")
116   par(mfrow = c(1, 1))
117 }
118
119 cat("\nBalance Check ARMA(2,1):\n")
120 check_residuals(arma21)
121
122 cat("\nBalance Check ARMA(1,1):\n")
123 check_residuals(arma11)
124
125 # Καλύτερο μοντέλο
126 best_model <- arma21
127
128 # Πρόβλεψη 6 μηνών
129 forecast_values <- predict(best_model, n.ahead = 6)
130
131 # Γραφική παράσταση
132 plot(diff_unemp,
133      main = "Πρόβλεψη Πρώτων Διαφορών (ARMA(2,1))",
134      xlab = "Έτος",
135      ylab = "Διαφορά",
136      xlim = c(2022, 2025.5),
137      col = "darkblue",
138      lwd = 2)
139 lines(ts(forecast_values$pred, start = end(diff_unemp), frequency =
140         12),
141       col = "red", lwd = 2)
142 legend("topright",
143       legend = c("Πραγματικές", "Προβλέψεις"),
144       col = c("darkblue", "red"),
145       lwd = 2)
146
147 #1.d
148 # --- ΠΡΟΣΑΡΜΟΓΗ ARIMA(2,1,1) ---
149 arima_model <- arima(unemp_ts, order = c(2, 1, 1))
150
151 # --- ΑΝΑΛΥΣΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ---
152 # Συντελεστές και p-values
153 coefs <- arima_model$coef
154 se <- sqrt(diag(arima_model$var.coef))
155 z_stats <- coefs / se

```

```

155 p_values <- 2 * (1 - pnorm(abs(z_stats)))
156 results <- data.frame(
157   Estimate = coefs,
158   Std.Error = se,
159   z.value = z_stats,
160   p.value = p_values
161 )
162 print(results)
163
164 # --- ΕΛΕΓΧΟΣ ΚΑΤΑΛΟΙΠΩΝ ---
165 par(mfrow = c(1, 2))
166 acf(resid(arima_model), main = "ACF Καταλοίπων")
167 pacf(resid(arima_model), main = "PACF Καταλοίπων")
168 par(mfrow = c(1, 1))
169 # Ljung-Box test (12 lags)
170 box_test <- Box.test(resid(arima_model), type = "Ljung-Box", lag =
171   12)
172 print(box_test)
173
174 # --- ΠΡΟΒΛΕΨΗ 12 ΜΗΝΕΣ ΜΠΡΟΣΤΑ ---
175 forecast_values <- predict(arima_model, n.ahead = 12)
176
177 # --- ΔΙΑΓΡΑΜΜΑ ---
178 plot(unemp_ts,
179   main = "Πρόβλεψη Ανεργίας (ARIMA(2,1,1))",
180   xlim = c(2022, 2026),
181   ylim = c(10, 14),
182   ylab = "Ποσοστό Ανεργίας (%)",
183   xlab = "Έτος")
184 # Προβλέψεις κόκκινη ( γραμμή)
185 lines(ts(forecast_values$pred, start = end(unemp_ts) + c(0, 1),
186   frequency = 12), col = "red", lwd = 2)
187 # Διαστήματα εμπιστοσύνης μπλε ( διακεκομμένες)
188 lines(ts(forecast_values$pred + 1.96 * forecast_values$se, start =
189   end(unemp_ts) + c(0, 1), frequency = 12), col = "blue", lty = 2)
190 lines(ts(forecast_values$pred - 1.96 * forecast_values$se, start =
191   end(unemp_ts) + c(0, 1), frequency = 12), col = "blue", lty = 2)
192 # Υπόμνημα
193 legend("topright",
194   legend = c("Πραγματικά", "Πρόβλεψη", "95% Διάστημα"),
195   col = c("black", "red", "blue"),
196   lty = c(1, 1, 2),
197   lwd = 2)
198
199 # --- Επιστροφή σε μονοπλότ ---
200 par(mfrow = c(1, 1))
201
202 #ζ1.
203
204 # --- Αρχικό μοντέλο (ARIMA(2,1,1)) ---
205 arima_211 <- arima(unemp_ts, order = c(2, 1, 1))

```

```

202 aic_211 <- AIC(arima_211)
203 lb_211 <- Box.test(resid(arima_211), type = "Ljung-Box", lag = 12)$p.
      value
204
205 # --- Διευρυμένα μοντέλα ---
206 arima_311 <- arima(unemp_ts, order = c(3, 1, 1))
207 aic_311 <- AIC(arima_311)
208 lb_311 <- Box.test(resid(arima_311), type = "Ljung-Box", lag = 12)$p.
      value
209
210 arima_212 <- arima(unemp_ts, order = c(2, 1, 2))
211 aic_212 <- AIC(arima_212)
212 lb_212 <- Box.test(resid(arima_212), type = "Ljung-Box", lag = 12)$p.
      value
213
214 arima_221 <- arima(unemp_ts, order = c(2, 2, 1))
215 aic_221 <- AIC(arima_221)
216 lb_221 <- Box.test(resid(arima_221), type = "Ljung-Box", lag = 12)$p.
      value
217
218 # --- Συγκεντρωτικός πίνακας ---
219 models <- c("ARIMA(2,1,1)", "ARIMA(3,1,1)", "ARIMA(2,1,2)", "ARIMA
      (2,1,2)")
220 aic_values <- c(aic_211, aic_311, aic_212, aic_221)
221 lb_pvalues <- c(lb_211, lb_311, lb_212, lb_221)
222 summary_table <- data.frame(Model = models, AIC = aic_values,
      LjungBox_p = lb_pvalues)
223 print(summary_table)
224
225 # --- Έλεγχος καταλοίπων του καλύτερου μοντέλου με (το μικρότερο AIC)
      ---
226 best_model_index <- which.min(aic_values)
227 best_model_name <- models[best_model_index]
228 cat("Καλύτερο μοντέλο:", best_model_name, "\n")
229 if(best_model_index == 1) best_model <- arima_211
230 if(best_model_index == 2) best_model <- arima_311
231 if(best_model_index == 3) best_model <- arima_212
232 if(best_model_index == 4) best_model <- arima_221
233
234 # Διάγραμμα υπολοίπων
235 par(mfrow = c(1, 2))
236 acf(resid(best_model), main = paste("ACF Καταλοίπων", best_model_name
      ))
237 pacf(resid(best_model), main = paste("PACF Καταλοίπων", best_model_
      name))
238 par(mfrow = c(1, 1))
239
240 #η1.
241
242 # Πρόβλεψη 24 μηνών μπροστά με το τελικό μοντέλο
243 forecast_values <- predict(arima_311, n.ahead = 24)

```

```

244 # Προσάρμοστο plotting στις ανάγκες σου :
245 plot(unemp_ts,
246      xlim = c(2022, 2027),
247      ylim = c(min(unemp_ts, forecast_values$pred - 1.96*forecast_
248                values$se), max(unemp_ts, forecast_values$pred + 1.96*
249                forecast_values$se)),
250      main = "Πρόβλεψη ποσοστού ανεργίας (24 μήνες μπροστά)",
251      ylab = "Ποσοστό ανεργίας (%)",
252      xlab = "Έτος")
253 lines(ts(forecast_values$pred, start = end(unemp_ts) + c(0, 1),
254          frequency = 12), col = "red", lwd = 2)
255 lines(ts(forecast_values$pred + 1.96 * forecast_values$se, start =
256          end(unemp_ts) + c(0, 1), frequency = 12), col = "blue", lty = 2)
257 lines(ts(forecast_values$pred - 1.96 * forecast_values$se, start =
258          end(unemp_ts) + c(0, 1), frequency = 12), col = "blue", lty = 2)
259 legend("topright",
260       legend = c("Ιστορικά", "Πρόβλεψη", "95% Διάστημα"),
261       col = c("black", "red", "blue"),
262       lty = c(1, 1, 2), lwd = 2)

```

Listing 2: R code για Άσκηση 2 - Ανάλυση Μηνιαίας Βροχόπτωσης με SARIMA

```

1 #2.a
2
3 data <- read.csv("C:/Users/pathana/Documents/predictive analytics/
4   open-meteo-37.93N22.83E37m.csv", skip = 2)
5 head(data)
6
7 names(data)
8 head(data)
9
10 data$date <- as.Date(substr(data$time, 1, 10))
11 data$year <- format(data$date, "%Y")
12 data$month <- format(data$date, "%m")
13
14 monthly_rain <- aggregate(data[, "rain..mm."],
15                            by = list(year = data$year, month = data$
16                            month),
17                            FUN = sum, na.rm = TRUE)
18 names(monthly_rain)[3] <- "rain_sum"
19
20 # Δημιουργία χρονοσειράς
21 ts_rain <- ts(monthly_rain$rain_sum, start = c(as.numeric(monthly_
22   rain$year[1]), as.numeric(monthly_rain$month[1])), frequency = 12)
23 plot(ts_rain, main = "Μηνιαία Βροχόπτωση Ζευγολατιού Κορινθίας (2016
24   - 2025)", ylab = "mm", xlab = "Έτος")
25
26 #β2.
27 acf(ts_rain, main = "ACF Μηνιαίας Βροχόπτωσης ")
28 pacf(ts_rain, main = "PACF Μηνιαίας Βροχόπτωσης ")
29

```

```

26 # γ2.: Πρώτες εποχικές διαφορές και ανάλυση στασιμότητας
27 seas_diff <- diff(ts_rain, lag = 12)
28 plot(seas_diff, main = "Πρώτες Εποχικές Διαφορές (Lag=12)", ylab = "
    Διαφορά (mm)", xlab = "Έτος")
29 grid(col = "gray", lty = "dotted")
30
31 par(mfrow = c(1, 2))
32 acf(seas_diff, lag.max = 36, main = "ACF: Εποχικές Διαφορές ", col = "
    darkblue")
33 pacf(seas_diff, lag.max = 36, main = "PACF: Εποχικές Διαφορές ", col =
    "darkred")
34 par(mfrow = c(1, 1))
35
36 years <- unique(floor(time(seas_diff)))
37 means <- tapply(seas_diff, floor(time(seas_diff)), mean)
38 vars <- tapply(seas_diff, floor(time(seas_diff)), var)
39
40 cat("Μέσοι Όροι ανά Έτος :\n", round(means, 2), "\n")
41 cat("Διακυμάνσεις ανά Έτος :\n", round(vars, 2), "\n")
42
43 if (max(vars)/min(vars) < 4 && diff(range(means)) < 2*sd(seas_diff))
44 {
45     cat("Στάσιμη Σειρά σταθερός ( μέσος και διακύμανση )")
46 } else {
47     cat("Μη Στάσιμη Σειρά ")
48 }
49
50 #ε2.
51 double_diff <- diff(diff(ts_rain, lag = 12), differences = 1)
52 plot(double_diff, main = "Διπλή Διαφοροποίηση Πρώτες ( +
    Εποχικές Διαφορές )", ylab = "Διαφορά (mm)", xlab = "Έτος", col = "
    darkblue", lwd = 2)
53 grid(col = "gray", lty = "dotted")
54
55 par(mfrow = c(1, 2))
56 acf(double_diff, lag.max = 36, main = "ACF: Διπλές Διαφορές ", col = "
    darkred")
57 pacf(double_diff, lag.max = 36, main = "PACF: Διπλές Διαφορές ", col =
    "darkgreen")
58 par(mfrow = c(1, 1))
59
60 #στ2.
61 fit_sarima <- stats::arima(
62     ts_rain,
63     order = c(2, 1, 1),
64     seasonal = list(order = c(1, 1, 1), period = 12)
65 )
66
67 cat("Παράμετροι Μοντέλου:\n")
68 print(fit_sarima$coef)
69 cat("\nΣτατιστικά:\n")

```

```

69 cat("AIC:", fit_sarima$aic, "\n")
70 cat("log-likelihood:", fit_sarima$loglik, "\n")
71
72 residuals_sarima <- residuals(fit_sarima)
73 acf_plot <- function(res, main = "ACF Καταλοίπων") {
74   n <- length(res)
75   acf_vals <- acf(res, plot = FALSE)$acf[-1]
76   lags <- 1:length(acf_vals)
77   plot(lags, acf_vals, type = "h", main = main, ylim = c(-1, 1), xlab
       = "Lag", ylab = "ACF")
78   abline(h = 0, col = "black")
79   abline(h = c(-1.96, 1.96)/sqrt(n), col = "blue", lty = 2)
80 }
81 pacf_plot <- function(res, main = "PACF Καταλοίπων") {
82   n <- length(res)
83   pacf_vals <- pacf(res, plot = FALSE)$acf
84   lags <- 1:length(pacf_vals)
85   plot(lags, pacf_vals, type = "h", main = main, ylim = c(-1, 1),
       xlab = "Lag", ylab = "PACF")
86   abline(h = 0, col = "black")
87   abline(h = c(-1.96, 1.96)/sqrt(n), col = "blue", lty = 2)
88 }
89 par(mfrow = c(1, 3))
90 acf_plot(residuals_sarima)
91 pacf_plot(residuals_sarima)
92 hist(residuals_sarima, main = "Ιστόγραμμα Καταλοίπων", col = "
    lightblue")
93 par(mfrow = c(1, 1))
94
95 ljung_box_test <- function(res, lag = 24) {
96   n <- length(res)
97   lb_test <- Box.test(res, lag = lag, type = "Ljung-Box")
98   cat("Ljung-Box test (lag =", lag, "):\n")
99   cat("X-squared =", lb_test$statistic, " p-value =", lb_test$p.value
    , "\n")
100   if (lb_test$p.value > 0.05) {
101     cat("Δεν υπάρχει αυτοσυσχέτιση καλά ( καταλοιπα)\n")
102   } else {
103     cat("Υπάρχει αυτοσυσχέτιση προβληματικά ( καταλοιπα)\n")
104   }
105 }
106 ljung_box_test(residuals_sarima)
107
108 future_forecast <- predict(fit_sarima, n.ahead = 12)
109 last_obs_time <- tail(time(ts_rain), 1)
110 forecast_dates <- last_obs_time + (1:12)/12
111 plot(ts_rain, main = "Πρόβλεψη Μηνιαίας Βροχόπτωσης ", xlab = "Έτος",
    ylab = "Βροχόπτωση (mm)", xlim = c(start(ts_rain)[1], last_obs_
    time + 13/12), ylim = c(0, max(c(ts_rain, future_forecast$pred +
    1.96*future_forecast$se), na.rm = TRUE)))
112 last_obs_value <- tail(ts_rain, 1)

```



```

113 lines(c(last_obs_time, forecast_dates[1]), c(last_obs_value, future_
      forecast$pred[1]), col = "red", lwd = 2)
114 lines(forecast_dates, future_forecast$pred, col = "red", lwd = 2)
115 lines(forecast_dates, future_forecast$pred + 1.96 * future_forecast$
      se, col = "blue", lty = 2)
116 lines(forecast_dates, future_forecast$pred - 1.96 * future_forecast$
      se, col = "blue", lty = 2)
117 legend("topleft",
118       legend = c("Παρατηρήσεις", "Πρόβλεψη", "95%
          Διάστημα Εμπιστοσύνης"),
119       col = c("black", "red", "blue"),
120       lty = c(1, 1, 2),
121       cex = 0.8)
122
123 #ζ2.
124 residuals_sarima <- residuals(fit_sarima)
125 par(mfrow = c(2, 2))
126 plot(residuals_sarima, main = "Κατάλοιπα ανά Χρόνο ", ylab = "
      Κατάλοιπα")
127 abline(h = 0, col = "red")
128 acf(residuals_sarima, main = "ACF Καταλοίπων", col = "darkblue")
129 pacf(residuals_sarima, main = "PACF Καταλοίπων", col = "darkred")
130 qqnorm(residuals_sarima, main = "Q-Q Plot")
131 qqline(residuals_sarima, col = "blue")
132 par(mfrow = c(1, 1))
133 Box.test(residuals_sarima, lag = 24, type = "Ljung-Box")
134
135 original_model <- fit_sarima
136 original_aic <- original_model$aic
137 model_ar_up <- arima(ts_rain, order = c(3, 1, 1), seasonal = list(
      order = c(1, 1, 1), period = 12))
138 model_ma_up <- arima(ts_rain, order = c(2, 1, 2), seasonal = list(
      order = c(1, 1, 1), period = 12))
139 model_sar_up <- arima(ts_rain, order = c(2, 1, 1), seasonal = list(
      order = c(2, 1, 1), period = 12))
140 model_sma_up <- arima(ts_rain, order = c(2, 1, 1), seasonal = list(
      order = c(1, 1, 2), period = 12))
141 model_full_up <- arima(ts_rain, order = c(3, 1, 2), seasonal = list(
      order = c(2, 1, 2), period = 12))
142
143 models <- list(
144   "Original" = original_model,
145   "AR+1" = model_ar_up,
146   "MA+1" = model_ma_up,
147   "SAR+1" = model_sar_up,
148   "SMA+1" = model_sma_up,
149   "Full+1" = model_full_up
150 )
151 compare_models <- function(model_list) {
152   results <- data.frame(
153     Model = names(model_list),

```

```

154     AIC = sapply(model_list, function(m) m$aic),
155     LogLik = sapply(model_list, function(m) m$loglik),
156     stringsAsFactors = FALSE
157 )
158 results$DeltaAIC <- results$AIC - original_aic
159 results[order(results$AIC), ]
160 }
161 model_comparison <- compare_models(models)
162 print(model_comparison)
163 check_residuals <- function(model) {
164   res <- residuals(model)
165   par(mfrow = c(1, 3))
166   acf(res, main = "ACF Καταλοίπων", col = "darkblue")
167   pacf(res, main = "PACF Καταλοίπων", col = "darkred")
168   qqnorm(res, main = "Q-Q Plot")
169   qqline(res, col = "blue")
170   par(mfrow = c(1, 1))
171   lb_test <- Box.test(res, lag = 24, type = "Ljung-Box")
172   cat("Ljung-Box test p-value:", lb_test$p.value, "\n")
173 }
174 best_model_name <- model_comparison$Model[which.min(model_comparison$
  AIC)]
175 best_model <- models[[best_model_name]]
176 cat("\nΈλεγχος Καταλοίπων για το Βέλτιστο Μοντέλο      :", best_model_name,
  "\n")
177 check_residuals(best_model)
178 if (model_comparison$DeltaAIC[model_comparison$Model == best_model_
  name] < -2) {
179   cat("\nΤο αρχικό μοντέλο ΔΕΝ είναι επαρκές      .
    Το βέλτιστο μοντέλο είναι      ", best_model_name)
180 } else {
181   cat("\nΤο αρχικό μοντέλο είναι επαρκές      .")
182 }
183
184 #η2.
185 forecast_24m <- predict(fit_sarima, n.ahead = 24)
186 last_obs_time <- end(ts_rain)
187 last_obs_value <- tail(ts_rain, 1)
188 forecast_times <- seq(last_obs_time[1] + (last_obs_time[2])/12 + 1/
  12, by = 1/12, length.out = 24)
189 plot(ts_rain,
190     main = "Πρόβλεψη Μηνιαίας Βροχόπτωσης (2 Έτη)",
191     xlab = "Έτος",
192     ylab = "Βροχόπτωση (mm)",
193     xlim = c(start(ts_rain)[1], last_obs_time[1] + 3),
194     ylim = c(0, max(ts_rain, forecast_24m$pred + 1.96*forecast_24m$
      se, na.rm = TRUE)),
195     lwd = 2)
196 segments(x0 = last_obs_time[1] + (last_obs_time[2]-1)/12, y0 = last_
  obs_value,
197     x1 = forecast_times[1], y1 = forecast_24m$pred[1], col = "

```

```

200         red", lwd = 2)
201 lines(forecast_times, forecast_24m$pred, col = "red", lwd = 2)
202 lines(forecast_times, forecast_24m$pred + 1.96 * forecast_24m$se, col
    = "blue", lty = 2)
203 lines(forecast_times, forecast_24m$pred - 1.96 * forecast_24m$se, col
    = "blue", lty = 2)
204 legend("topleft",
205     legend = c("Ιστορικά Δεδομένα", "Πρόβλεψη SARIMA", "95%
        Διάστημα Εμπιστοσύνης "),
206     col = c("black", "red", "blue"),
207     lty = c(1, 1, 2),
208     lwd = c(2, 2, 1),
209     cex = 0.8)
210 abline(v = forecast_times[1], col = "green", lty = 2)
211 text(x = forecast_times[1], y = max(ts_rain)*0.9, "Έναρξη Πρόβλεψης",
212     pos = 4, col = "darkgreen", cex = 0.8)
213
214 year1 <- forecast_24m$pred[1:12]
215 year2 <- forecast_24m$pred[13:24]
216 historical_seasonal <- aggregate(as.vector(ts_rain) ~ cycle(ts_rain),
    FUN = mean)
217 par(mfrow = c(1, 2))
218 plot(1:12, year1, type = "o", col = "red", main = "Πρόβλεψη Έτος 1 vs
    Ιστορικό", xlab = "Μήνας", ylab = "Βροχόπτωση (mm)", ylim = range
    (historical_seasonal[,2], year1))
219 lines(1:12, historical_seasonal[,2], type = "o", col = "blue")
220 legend("topright", legend = c("Πρόβλεψη", "Ιστορικό"), col = c("red",
    "blue"), lty = 1)
221 plot(1:12, year2, type = "o", col = "red", main = "Πρόβλεψη Έτος 2 vs
    Ιστορικό", xlab = "Μήνας", ylab = "Βροχόπτωση (mm)", ylim = range
    (historical_seasonal[,2], year2))
222 lines(1:12, historical_seasonal[,2], type = "o", col = "blue")
223 par(mfrow = c(1, 1))
224 yearly_avg <- c(mean(year1), mean(year2))
225 se_avg <- c(mean(forecast_24m$se[1:12]), mean(forecast_24m$se[13:24])
    )
226 plot(1:2, yearly_avg, type = "b", col = "red", main = "Ετήσιος
    Μέσος Όρος Πρόβλεψης ", xlab = "Έτος Πρόβλεψης", ylab = "Μέση
    Βροχόπτωση (mm)", ylim = c(min(yearly_avg - 1.96*se_avg), max(
    yearly_avg + 1.96*se_avg)))
227 arrows(x0 = 1:2, y0 = yearly_avg - 1.96*se_avg, x1 = 1:2, y1 = yearly
    _avg + 1.96*se_avg, angle = 90, code = 3, length = 0.1)
228 abline(h = mean(ts_rain), col = "blue", lty = 2)
229 legend("topright", legend = c("Πρόβλεψη", "Ιστορικός Μέσος Όρος "),
230     col = c("red", "blue"), lty = c(1, 2))
231
232 diff_year1 <- year1 - historical_seasonal[,2]
233 diff_year2 <- year2 - historical_seasonal[,2]
234 t_test_year1 <- t.test(diff_year1)
235 t_test_year2 <- t.test(diff_year2)
236 res_acf <- acf(forecast_24m$pred, main = "ACF Προβλέψεων")

```

```

232 pred_range <- apply(rbind(forecast_24m$pred - 1.96*forecast_24m$se,
    forecast_24m$pred + 1.96*forecast_24m$se), 2, diff)
233 cat("Διαφορά Έτους 1:", round((mean(year1) - mean(ts_rain))/mean(ts_
    rain)*100, 1), "%\n")
234 cat("Διαφορά Έτους 2:", round((mean(year2) - mean(ts_rain))/mean(ts_
    rain)*100, 1), "%")
235
236 test_size <- 24
237 train <- window(ts_rain, end = c(end(ts_rain)[1]-2, 12))
238 test <- window(ts_rain, start = c(end(ts_rain)[1]-1, 1))
239 fit_train <- arima(train, order = c(2,1,1), seasonal = list(order = c
    (1,1,1), period = 12))
240 test_forecast <- predict(fit_train, n.ahead = test_size)
241 errors <- test - test_forecast$pred
242 mae <- mean(abs(errors))
243 rmse <- sqrt(mean(errors^2))
244 plot(test, main = "Πραγματικές vs Προβλεπόμενες Τιμές ")
245 lines(ts(test_forecast$pred, start = start(test), frequency = 12),
    col = "red")

```

Listing 3: Άσκηση 3 – Ανάλυση Χρονοσειρών με AR, ARIMA και Εποχιακή Αποσύνθεση

```

1 # 3.1 Πρόβλεψη θνησιμότητας με AR(2)
2
3 library(astsa)
4
5 # Δημιουργία χρονοσειράς
6 ts_cmort <- ts(cmort, frequency = 52)
7
8 # Προσαρμογή AR(2)
9 ar2_fit <- arima(ts_cmort, order = c(2,0,0))
10
11 # Πρόβλεψη 4 εβδομάδων
12 forecast_horizon <- 4
13 forecast <- predict(ar2_fit, n.ahead = forecast_horizon)
14
15 # Διαστήματα εμπιστοσύνης 95%
16 upper_bound <- forecast$pred + 1.96 * forecast$se
17 lower_bound <- forecast$pred - 1.96 * forecast$se
18
19 # Σχεδίαση αποτελεσμάτων
20 n <- length(ts_cmort)
21 weeks <- (n - 30):(n + forecast_horizon)
22 plot(weeks[1:31], ts_cmort[(n-30):n], type = "l", lwd = 2,
23      ylim = range(ts_cmort[(n-30):n], upper_bound, lower_bound),
24      xlim = range(weeks),
25      main = "Πρόβλεψη θνησιμότητας AR(2)",
26      xlab = "Εβδομάδα", ylab = "Θνησιμότητα")
27 forecast_weeks <- (n + 1):(n + forecast_horizon)
28 lines(forecast_weeks, forecast$pred, col = "red", lwd = 2, type = "b"
    , pch = 16)

```

```

29 lines(forecast_weeks, upper_bound, col = "blue", lty = 2, lwd = 2)
30 lines(forecast_weeks, lower_bound, col = "blue", lty = 2, lwd = 2)
31 legend("topright",
32       legend = c("Ιστορικά", "Πρόβλεψη AR(2)", "95%
                 Διάστημα Εμπιστοσύνης "),
33       col = c("black", "red", "blue"),
34       lty = c(1, 1, 2), pch = c(NA, 16, NA), lwd = c(2,2,2), bty = "
                 n")
35
36 # Διαγνωστικά καταλοίπων
37 resid_ar2 <- residuals(ar2_fit)
38 par(mfrow = c(2,3))
39 plot(resid_ar2, type = "l", main = "Κατάλοιπα AR(2)", ylab = "
    Κατάλοιπα")
40 abline(h = 0, col = "red", lty = 2)
41 acf(resid_ar2, main = "ACF Καταλοίπων")
42 pacf(resid_ar2, main = "PACF Καταλοίπων")
43 hist(resid_ar2, breaks = 20, col = "lightblue", main = "Ιστόγραμμα
    Καταλοίπων")
44 qqnorm(resid_ar2); qqline(resid_ar2, col = "red")
45 plot(weeks[1:31], ts_cmort[(n-30):n], type = "l", lwd = 2, main = "
    Τελευταίες Τιμές", xlab = "Εβδομάδα", ylab = "Θνησιμότητα")
46 par(mfrow = c(1,1))
47
48 # Ljung-Box test
49 lb <- Box.test(resid_ar2, lag = 10, type = "Ljung-Box")
50 cat("Ljung-Box test p-value:", lb$p.value, "\n")
51 cat("Συντελεστές:\n"); print(ar2_fit$coef)
52 cat("AIC:", ar2_fit$aic, "\n")
53
54
55 # 3.2 Ανάλυση και πρόβλεψη παγκόσμιας θερμοκρασίας με ARIMA
56
57 library(astsa)
58 data(gtemp_land)
59 years <- 1850:2023
60 x_ts <- ts(gtemp_land, start = 1850, frequency = 1)
61
62 # Αρχικό διάγραμμα
63 plot(x_ts, main = "Παγκόσμια Θερμοκρασία Ξηράς (1850-2023)", ylab = "
    Απόκλιση (°C)", xlab = "Έτος")
64
65 # ACF/PACF αρχικής σειράς και της 1 διαφοράς
66 par(mfrow = c(1,2))
67 acf(x_ts, main = "ACF αρχικής σειράς ")
68 pacf(x_ts, main = "PACF αρχικής σειράς ")
69 par(mfrow = c(1,1))
70 dx_ts <- diff(x_ts)
71 plot(dx_ts, main = "η1 Διαφορά σειράς ", ylab = "Διαφορά
    από προηγούμενο έτος ", xlab = "Έτος")
72 par(mfrow = c(1,2))

```

```

73 acf(dx_ts, main = "ACF ης1 διαφοράς")
74 pacf(dx_ts, main = "PACF ης1 διαφοράς")
75 par(mfrow = c(1,1))
76
77 # Μοντέλο ARIMA(1,1,1)
78 fit <- arima(x_ts, order = c(1,1,1))
79 resid_fit <- residuals(fit)
80
81 # Διαγνωστικά καταλοίπων
82 par(mfrow = c(2,2))
83 plot(resid_fit, main = "Υπολείμματα ARIMA", ylab = "Υπολείμματα")
84 acf(resid_fit, main = "ACF Υπολειμμάτων")
85 pacf(resid_fit, main = "PACF Υπολειμμάτων")
86 hist(resid_fit, main = "Ιστογράμμα Υπολειμμάτων", col = "lightblue")
87 par(mfrow = c(1,1))
88
89 # Ljung-Box test
90 lb_test <- Box.test(resid_fit, lag = 20, type = "Ljung-Box")
91 cat("Ljung-Box p-value:", lb_test$p.value, "\n")
92 cat("AIC:", fit$aic, "\n")
93 cat("Συντελεστές:\n")
94 print(fit$coef)
95
96 # Πρόβλεψη για 10 χρόνια
97 n_forecast <- 10
98 pred <- predict(fit, n.ahead = n_forecast)
99 z <- qnorm(0.975)
100 upper <- pred$pred + z * pred$se
101 lower <- pred$pred - z * pred$se
102 last_year <- end(x_ts)[1]
103 forecast_years <- (last_year + 1):(last_year + n_forecast)
104 forecast_years <- c(last_year, forecast_years)
105 forecast_pred <- c(tail(x_ts, 1), pred$pred)
106 upper <- c(tail(x_ts, 1), upper)
107 lower <- c(tail(x_ts, 1), lower)
108
109 # Οπτικοποίηση
110 plot(window(x_ts, start = 2000), type = "o", pch = 16, col = "blue",
111      xlim = c(2000, last_year + n_forecast),
112      ylim = range(c(x_ts, lower, upper), na.rm = TRUE),
113      main = "Πρόβλεψη Παγκόσμιας Θερμοκρασίας Ξηράς ",
114      xlab = "Έτος", ylab = "Απόκλιση (°C)")
115 lines(forecast_years, forecast_pred, type = "o", col = "red", pch =
116       18, lty = 2)
117 lines(forecast_years, upper, col = "darkgreen", lty = 3)
118 lines(forecast_years, lower, col = "darkgreen", lty = 3)
119 polygon(c(forecast_years, rev(forecast_years)), c(upper, rev(lower)),
120        col = rgb(0, 0.5, 0, 0.2), border = NA)
121 legend("topleft", legend = c("Ιστορικά", "Πρόβλεψη", "95% CI"),
122       col = c("blue", "red", "darkgreen"),
123       lty = c(1, 2, 1), pch = c(16, 18, NA), bg = "white")

```

```

123
124
125 # 3.3 Εποχική ανάλυση και τάση πωλήσεων νερού
126
127 # Εισαγωγή δεδομένων
128 sales_data <- data.frame(
129   Year = c(2016, 2017, 2018, 2019),
130   Winter = c(1, 2, 2, 1),
131   Spring = c(3, 2, 4, 3),
132   Summer = c(6, 7, 8, 8),
133   Autumn = c(4, 5, 5, 6)
134 )
135
136 # Μετατροπή σε χρονοσειρά
137 sales_ts <- ts(c(t(sales_data[, -1])), start = 2016, frequency = 4)
138
139 # Υπολογισμός εποχιακών δεικτών
140 decompose_sales <- decompose(sales_ts, type = "multiplicative")
141 seasonal_indices <- decompose_sales$seasonal[1:4]
142 cat("Εποχιακοί Δείκτες:\n")
143 print(round(seasonal_indices, 3))
144
145 # Αποεποχικοποίηση
146 deseasonalized_sales <- sales_ts / seasonal_indices
147
148 # Γραμμή τάσης
149 time_points <- time(sales_ts)
150 trend_model <- lm(deseasonalized_sales ~ time_points)
151 trend_line <- ts(fitted(trend_model), start = 2016, frequency = 4)
152
153 # Κυκλική συνιστώσα
154 cyclic_component <- deseasonalized_sales / trend_line
155
156 # Οπτικοποίηση
157 par(mfrow = c(2,2))
158 plot(sales_ts, main = "Πρωτογενείς Πωλήσεις", ylab = "Πωλήσεις εκατ.
    μπουκάλια", col = "blue")
159 legend("topleft", "Πρωτόγονη", col = "blue", lty = 1)
160 plot(deseasonalized_sales, main = "Αποεποχικοποιημένες Πωλήσεις",
    ylab = "Πωλήσεις", col = "red")
161 lines(trend_line, col = "darkgreen", lwd = 2)
162 legend("topleft", c("Αποεποχικοποιημένες", "Τάση"), col = c("red", "
    darkgreen"), lty = c(1,1))
163 plot(cyclic_component, main = "Κυκλική Μεταβολή", ylab = "Σχετικά
    Υπόλοιπα", col = "purple")
164 abline(h = 1, col = "gray", lty = 2)
165 legend("topleft", "Κυκλική", col = "purple", lty = 1)
166 barplot(seasonal_indices, names.arg = c("Χειμώνας", "Άνοιξη", "
    Καλοκαίρι", "Φθινόπωρο"),
    main = "Εποχιακοί Δείκτες", ylab = "Δείκτης")
167
168 par(mfrow = c(1,1))

```